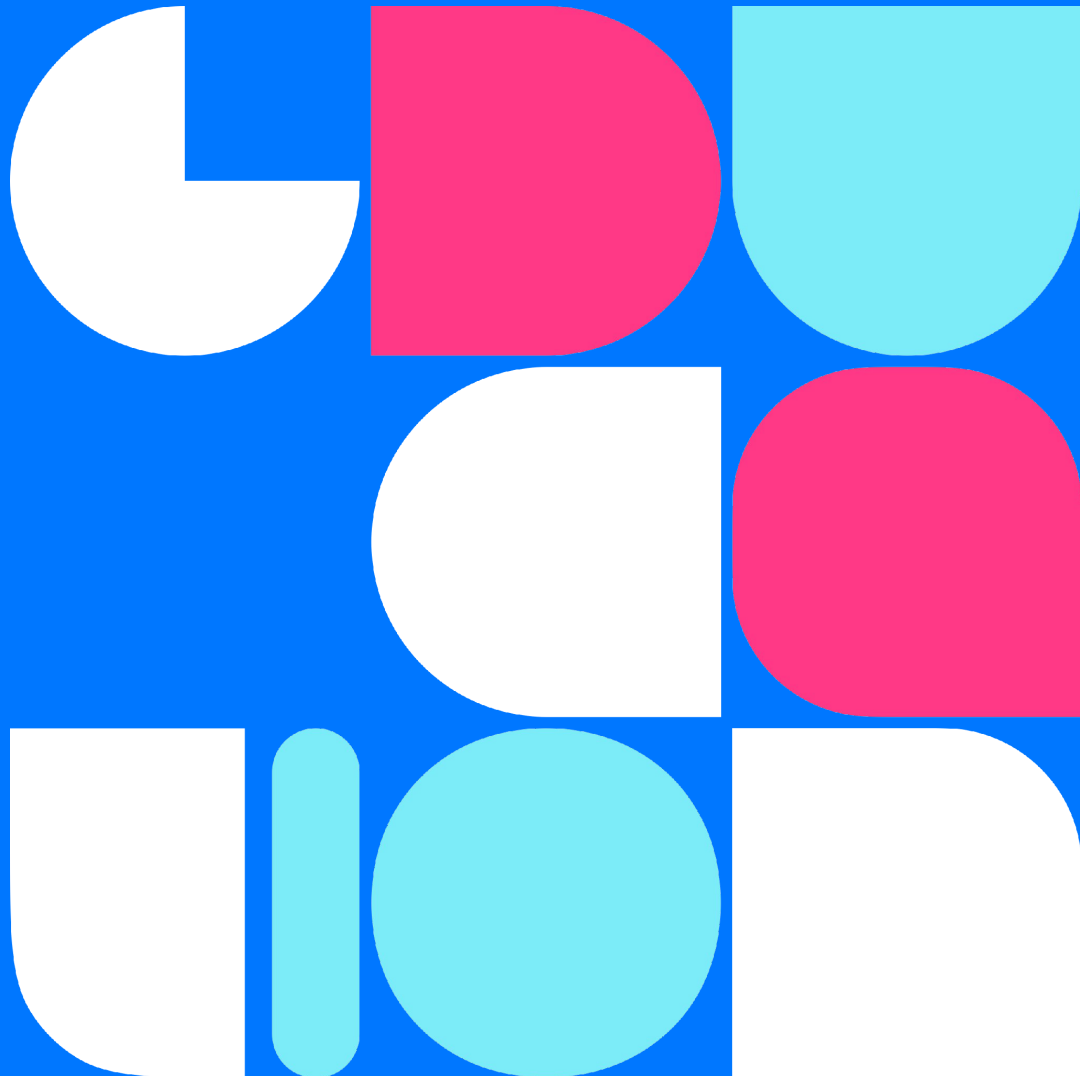
education

Текстовое ранжирование. Часть II

«Информационный поиск и ранжирование»
Преподаватель Руслан Аллаяров



Ведущий лекции



- Более 7 лет в ML, 6 лет из них в поиске
- Lead developer (реком товаров Ozon), Ex VK (поиск), Ex OKKO (реком главной витрины)
- Отвечал за блендинг поиска по видео, за базовое качество поиска по клипам и плейлистам
- Закончил мехмат МГУ и Техносферу (2021)

education

План лекции

1. Оценка качества: nDCG и MAP
2. Вероятностное ранжирование
3. BM25 и его семейство
4. Языковые модели для поиска
5. Близость слов и пассажи
6. Итоги и материалы
7. Домашнее задание 2
8. Семинар

Что мы уже знаем

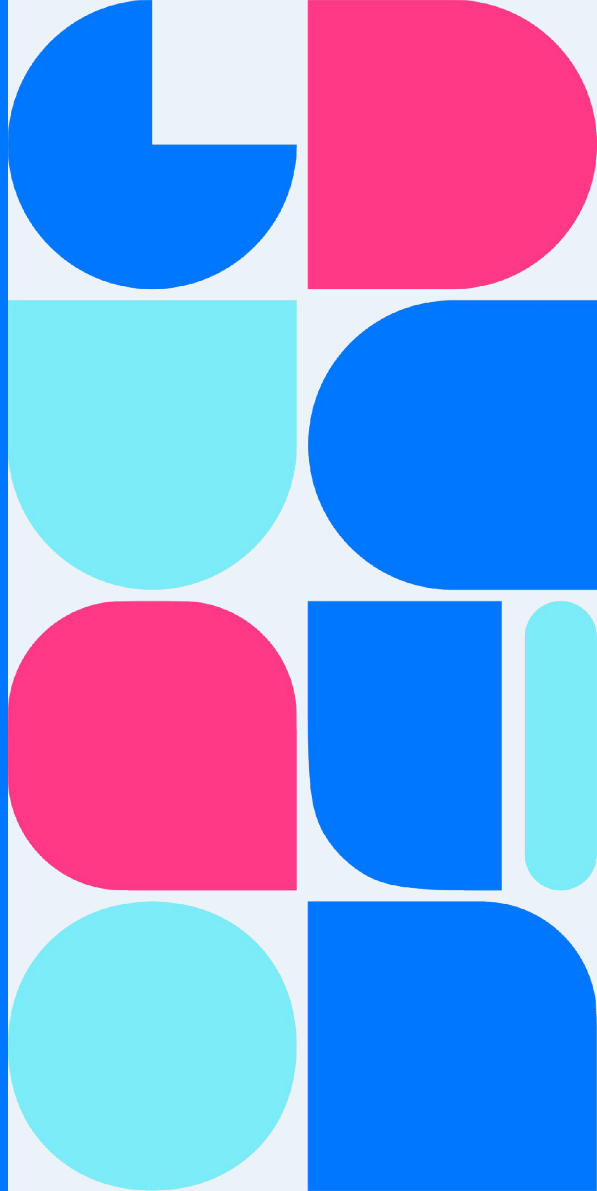
- **Часть I:** TF-IDF, модель векторного пространства, сублинейный TF
- **Часть I:** нормализация длины (pivoted), аксиомы TFC / TDC / LNC
- **Часть I:** P@K, Recall@K, MRR — метрики для бинарной релевантности
- **Лекция 2:** координатный индекс — позиции слов в постингах
- **Лекция 3:** n-граммные языковые модели и сглаживание

Открытые вопросы

1. Почему в IDF логарифм?
2. Можно ли вывести формулу, а не угадать?
3. Что делать, если оценки не 0/1, а 0/1/2/3?
4. Как учесть порядок слов?

Оценка качества: nDCG и MAP

Мерить качество, когда релевантность бывает разной степени



Что такое релевантность

- Релевантный документ удовлетворяет информационную потребность
- Потребность часто неоднозначна: «ягуар» — машина, животное или напиток?
- Документ может быть полезен частично: «полезный», но не «ответ»
- Поэтому бинарной шкалы 0/1 часто мало







Запрос «ягуар»: какой из документов релевантен?

Асессорская оценка

- Асессоры получают задание: насколько документ d релевантен запросу q
- Краудсорсинг (Яндекс Задания, бывшая Толока) или своя платформа (в VK — SQ)
- Градуированная шкала, например:
  - 1 — нерелевантно: yandex.ru по запросу «вк»
  - 2 — полезно: VK Музыка по запросу «вк»
  - 3 — релевантно: vk.com по запросу «вк»
- Оценённые пары потом становятся датасетом для обучения моделей



насекомые синий трактор ВСЕ ЗАПРОСЫ

ВЫБОРКА НА GOGO.ST

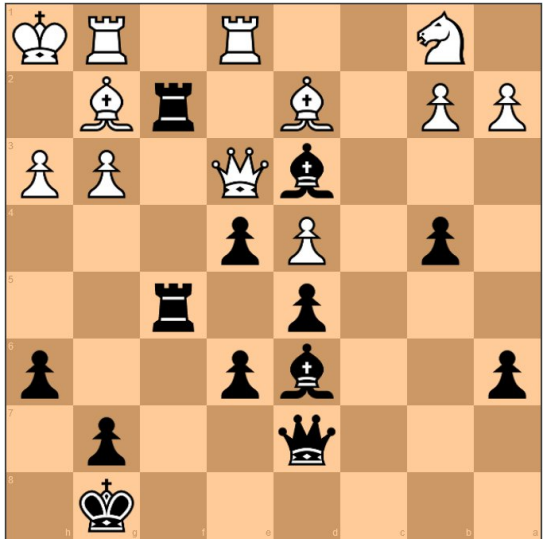
[youtube new] sm6, best vk model #70

V-LDCG-10 = 19.78

Позиция	Серп	Оценка
1	https://vk.com/video148631493_456239808	2
2	https://vk.com/video-211391900_456239201	3
3	https://vk.com/video-85859225_456240469	3
4	https://vk.com/video-7966621_456239049	1
5	https://vk.com/video217045772_456239072	2
6	https://vk.com/video-221593574_456239210	2
7	https://vk.com/video1218682_456240188	3
8	https://vk.com/video536711804_456239047	2
9	https://vk.com/video59161431_456239984	2
10	https://vk.com/video176207939_456239071	3

Разметка выдачи VK Видео по 3-балльной шкале на платформе SQ

Разметка не абсолютна



Насколько позиция релевантна запросу «цугцванг»? Асессор-не-шахматист не ответит

Collection	Consistent	Inconsistent	(% of Total)
T123	689	120	15%
T6	228	45	16%
T78	308	71	19%
WT10G-binary	1413	293	17%
GOV2-binary	10138	2346	19%
WT10G-trinary	1374	332	19%
GOV2-trinary	9504	2980	24%

Table 1: Consistency of relevance judgments across TREC collections. The columns show a count of the number of pairs of duplicate documents that were judged consistently and inconsistently, followed by the percentage proportion of inconsistent pairs. Only duplicates where at least one document was judged to be relevant are included.

Один и тот же асессор оценивает дубликаты по-разному в 15–24% случаев (Scholer et al., 2011)

- Асессор не разбирается в теме
- Не может оценить авторитетность источника
- Разные асессоры — разные оценки
- Решение: перекрытие, инструкции, проверочные задания

LLM вместо асессоров

- LLM дают оценку релевантности по инструкции, как асессор
- Bing: LLM-разметка по качеству сопоставима с разметкой людьми (Thomas et al., SIGIR 2024)
- TREC 2024: рейтинги систем по LLM-оценкам (UMBRELA) сильно коррелируют с рейтингами по оценкам людей
- Быстро и дёшево, можно разметить в сотни раз больше пар

Где хорошо

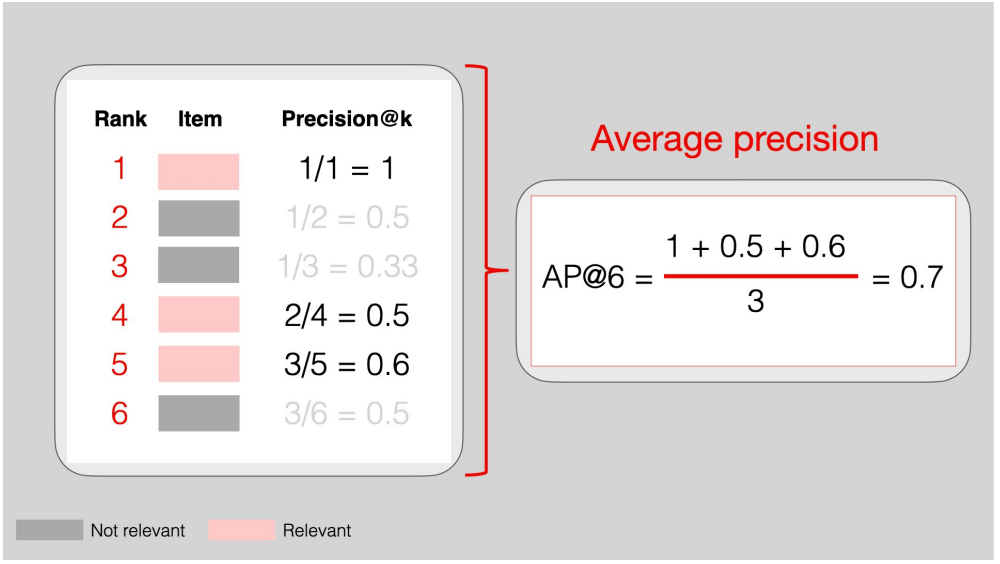
1. Сравнение систем между собой
2. Разметка обучающих данных

Где осторожно

1. Оценивать LLM-ранкер LLM-судьёй
2. Узкие домены и свежие события

Повторение из лекции 1

Average Precision и MAP



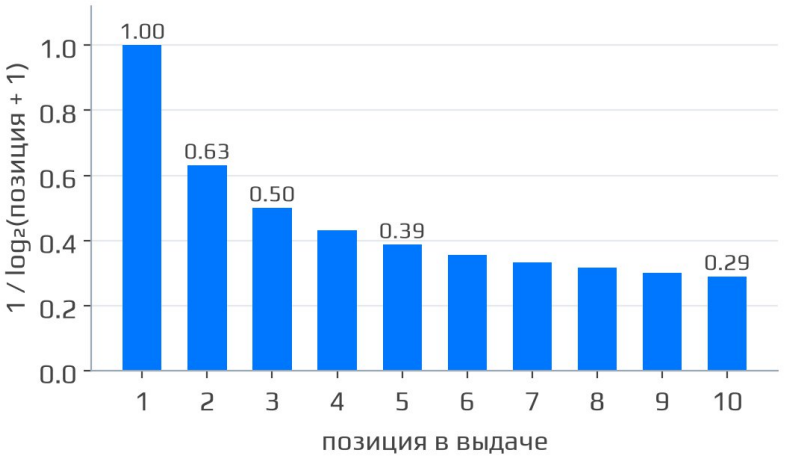
AP@6: усредняем Precision@k по позициям релевантных документов (evidentlyai.com)

- Считаем Precision@k в каждой позиции, где стоит релевантный документ
- AP — среднее этих значений (делим на число релевантных)
- MAP — среднее AP по всем запросам
- Чувствительна к порядку во всём топе, а не только к первому ответу
- Шкала бинарная

DCG: дисконтированный выигрыш

$$DCG@K = \Sigma\ (2^{rel_i} - 1)\ /\ \log_2(i + 1)$$

- rel_i — оценка документа на позиции i (0, 1, 2, 3…)
- Числитель — выигрыш (gain): сильно релевантные ценнее
- Знаменатель — дисконт: нижние позиции весят меньше
- Есть вариант с gain = rel_i: другая шкала, тот же смысл



Дисконт: 10-я позиция весит в 3.4 раза меньше первой

nDCG: нормируем на идеал

$$\mathrm{nDCG@K} = \mathrm{DCG@K} / \mathrm{IDCG@K}, \quad \mathrm{IDCG} — \mathrm{DCG}\ \text{идеальной сортировки}$$

Пример: оценки в выдаче [2, 0, 3, 1], gain = rel

	Позиции 1–4	Расчёт	Значение
DCG@4	2, 0, 3, 1	2/1 + 0/1.58 + 3/2 + 1/2.32	3.93
IDCG@4	3, 2, 1, 0	3/1 + 2/1.58 + 1/2 + 0/2.32	4.76
nDCG@4		3.93 / 4.76	0.83

nDCG ∈ [0, 1] и сравнима между запросами. IDCG честно считают по всем размеченным документам запроса, а не только по выдаче

Неразмеченные документы

- Размечаем только пул: топы нескольких систем (лекция 4)
- Новая система находит документы, которых нет в разметке
- Обычно их считают нерелевантными → новая система недооценена
- Проверка: judged@10 — доля размеченных документов в топ-10
- Если judged@10 низкий — доразмечаем, а не радуемся

На семинаре (пт)

В MIRACL для каждого запроса размечены и релевантные, и нерелевантные пассажи. Посчитаем judged@10 для разных методов и увидим, когда метрика перестаёт быть честной

Какую метрику выбрать

Ситуация	Метрика
Один правильный ответ (QA, навигационные запросы)	MRR@K
Бинарная релевантность, важен весь топ	MAP, P@K
Градуированные оценки, важен порядок	nDCG@K
Отбор кандидатов перед переранжированием	Recall@K (K = 100…1000)

Рецепт

~1000 запросов из логов → топ-10 от нескольких систем → асессоры или LLM → nDCG@10. Разметку сохраняем: она пригодится для обучения (LTR)

Значимо ли улучшение?

1. Сравниваем попарно

запрос	A	B	δ = B − A
q1	0.62	0.70	+0.08
q2	0.00	0.00	0
q3	0.91	0.85	−0.06
…	…	…	…
среднее	0.661	0.677	+0.016

A = BM25, B = BM25F; строки q1–q3 для примера

От запроса к запросу nDCG гуляет от 0 до 1 — это намного больше разницы методов

Поэтому сравниваем не два средних, а разности δ на **одних и тех же** запросах

2. Шум или настоящая разница?

p-value: шанс увидеть такую разницу, если методы одинаковы. $p < 0.05$ — «значимо»

Парный t-тест: $t = \text{среднее } \delta \,/\, (s_\delta / \sqrt{n})$

Перестановочный тест: если методы одинаковы, знак δ случаен. 10 000 раз наугад меняем знаки; p — доля случаев, где |среднее| не меньше нашего

Smucker et al. (CIKM 2007): оба теста согласны; знаковый тест и Вилкоксон — нет

Где обманываемся

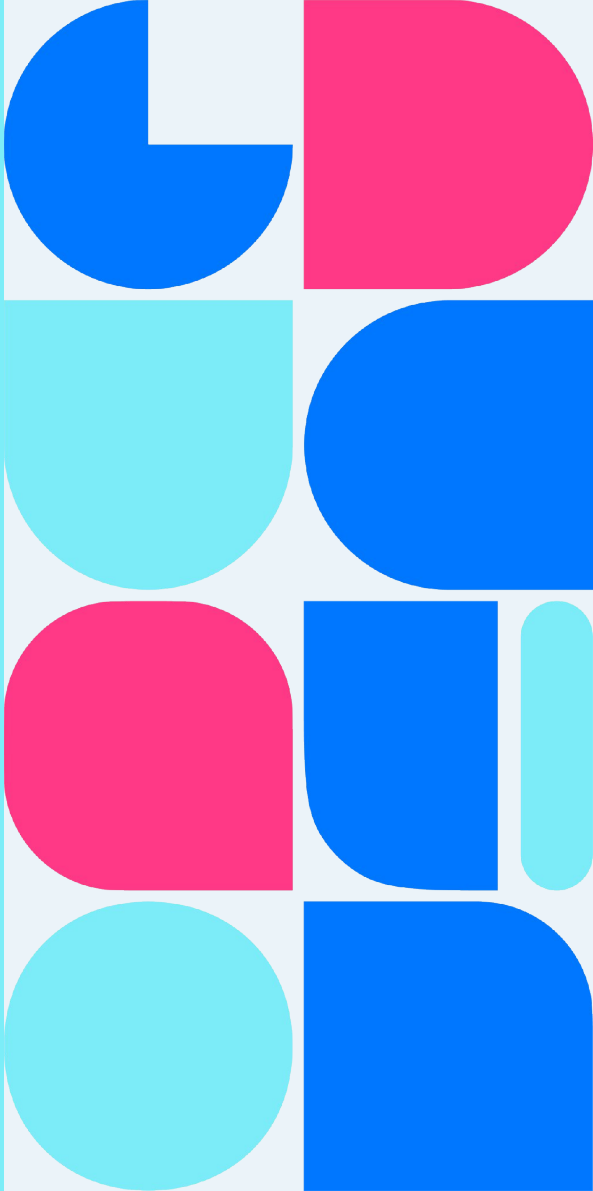
- **Мало запросов.** На 50 запросах разница в 1–2 пункта тонет в шуме: $s_\delta / \sqrt{n}$ велико
- **Много сравнений.** Из 20 бесполезных вариантов один «значим» при $p < 0.05$ — берём порог 0.05 / 20 (Бонферрони)
- **Подбор на test.** Параметры подбираем на dev, на test проверяем один раз
- **Значимо ≠ важно.** Смотрим и на p, и на размер разницы

На семинаре (пт): MIRACL, 852 запроса

A vs B	Δ nDCG@10	p	A лучше / хуже
BM25 vs TF-IDF	+0.036	< 0.0001	376 / 224
BM25F vs BM25	+0.016	0.001	285 / 244
LM Дирихле vs BM25	−0.012	0.015	250 / 315
k_1, b (dev) vs дефолт	−0.002	0.67	233 / 250

Вероятностное ранжирование

Вывести формулу ранжирования, а не угадать её — и понять, откуда в IDF логарифм



Почему вероятности

- Релевантность субъективна и зашумлена — это случайная величина $R \in \{0, 1\}$
- Запрос — неполное описание потребности
- Лучшее, что можно сделать: оценить $P(R = 1 \mid q, d)$
- Тогда задача: хорошо оценить вероятность и правильно ей воспользоваться



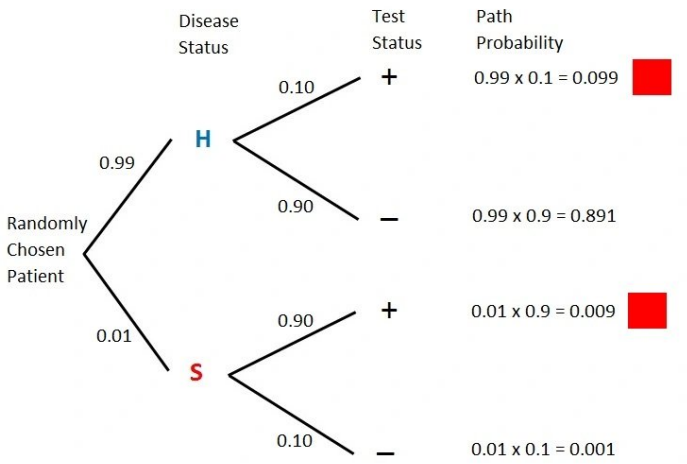
Кейт ван Рейсберген — один из основателей IR, автор F-меры

Probability Ranking Principle (Robertson, 1977)

Сортировка по убыванию $P(R = 1 \mid q, d)$ оптимальна, если вероятности оценены наилучшим образом по имеющимся данным и документы оцениваются независимо друг от друга

Байес: переворачиваем задачу

- P(R | d) напрямую не оценить
- Но можно оценить, как выглядят релевантные документы: P(d | R)
- Формула Байеса разворачивает одно в другое
- Для ранжирования удобнее отношение шансов — знаменатель P(d) сокращается



Классический пример: тест на болезнь и её вероятность

$$O(R \mid d, q) = P(R=1 \mid d, q) \,/\, P(R=0 \mid d, q) = O(R \mid q) \cdot P(d \mid R=1, q) \,/\, P(d \mid R=0, q)$$

Binary Independence Model

1. Документ — это «есть / нет» для каждого слова

Запрос: «столица Камбоджи»

	столица	камбоджа	пномпень	погода
d_1	1	1	1	0
d_2	1	0	0	1

Вектор длины |V| из нулей и единиц. Встретилось слово 1 раз или 10 — всё равно 1: частоту слова BIM не видит, это исправит BM25

2. Три упрощения

- **Бинарность.** Важен только факт: есть слово в документе или нет
- **Независимость.** Если релевантность известна, слова появляются независимо, как в наивном Байесе: $P(d \mid R) = \prod P(d_i \mid R)$
- **Слова не из запроса** одинаково часты в релевантных и нерелевантных: их множители равны 1 и сокращаются

Два параметра на каждое слово запроса

	что это	«камбоджа»	«столица»
$p_i = P(d_i = 1 \mid R = 1)$	доля релевантных документов, где есть слово	≈ 0.9	≈ 0.6
$u_i = P(d_i = 1 \mid R = 0)$	доля нерелевантных документов, где есть слово	≈ 0.0005	≈ 0.02

числа для примера

Как читать

Хорошее слово запроса встречается в релевантных часто (p_i велико) и редко во всех остальных (u_i мало)

«Камбоджа» лучше отличает нужные документы, чем «столица». Дальше выведем из p_i и u_i вес слова

Выводим RSV

1. Слова независимы по Байесу O(R | q) одинаков для всех документов — убираем; слова не из запроса сокращаются ($p_i = u_i$)

$$O(R \mid d, q) \propto \prod_{i \in q \cap d} p_i / u_i \cdot \prod_{i \in q \setminus d} (1 - p_i) / (1 - u_i)$$

слово запроса есть в документе: множитель p_i / u_i; слова нет: множитель $(1 - p_i) / (1 - u_i)$

2. Умножаем на единицу домножаем и делим на $(1 - p_i) / (1 - u_i)$ для найденных слов

$$O(R \mid d, q) \propto \prod_{i \in q \cap d} p_i (1 - u_i) / (u_i (1 - p_i)) \cdot \prod_{i \in q} (1 - p_i) / (1 - u_i)$$

второе произведение теперь по всем словам запроса — не зависит от документа, на порядок не влияет, убираем

3. Логарифм произведение превращается в сумму, порядок документов не меняется

$$RSV(q, d) = \sum_{i \in q \cap d} c_i, \quad c_i = \log p_i / (1 - p_i) + \log (1 - u_i) / u_i$$

Retrieval Status Value: скор — сумма весов c_i слов запроса, найденных в документе, как в TF-IDF. Первое слагаемое: насколько слово типично для релевантных. Второе: насколько оно редко среди нерелевантных — из него на следующем слайде получится IDF

Откуда берётся IDF

Если разметка есть: считаем документы

	релевантные	нерелевантные	всего
слово i есть	r	$DF - r$	DF
слова i нет	$R - r$	$N - DF - R + r$	$N - DF$
всего	R	$N - R$	N

$$p_i = r / R \qquad u_i = (DF - r) / (N - R)$$

Разметки нет: R = r = 0

- **Нерелевантные ≈ вся коллекция:** $u_i \approx DF / N$
- **О релевантных не знаем ничего:** $p_i = 0.5$ (Croft & Harper, 1979). Тогда $\log p_i / (1 - p_i) = \log 1 = 0$
- **От веса c_i остаётся только вторая половина**

$$c_i = \log (1 - u_i) / u_i = \log (N - DF) / DF \approx \log N / DF = IDF$$

Пример: N = 1 000 000 ln (N − DF + 0.5) / (DF + 0.5)

$DF = 100 \rightarrow 9.2$; $DF = 10\,000 \rightarrow 4.6$

$DF = 600\,000 \rightarrow -0.4$ DF > N / 2: вес меньше нуля

Круг замкнулся

IDF с логарифмом — не эвристика, а вес слова в BIM без разметки. Со сглаживанием +0.5 это IDF из BM25. Есть клики или оценки — подставляем r и R и получаем вес точнее IDF

Чего не хватает BIM

Проблемы

1. Не учитывает TF: слово один раз или сто — всё равно
2. Не учитывает длину документа
3. p_i без разметки неизвестны

Что хотим добавить

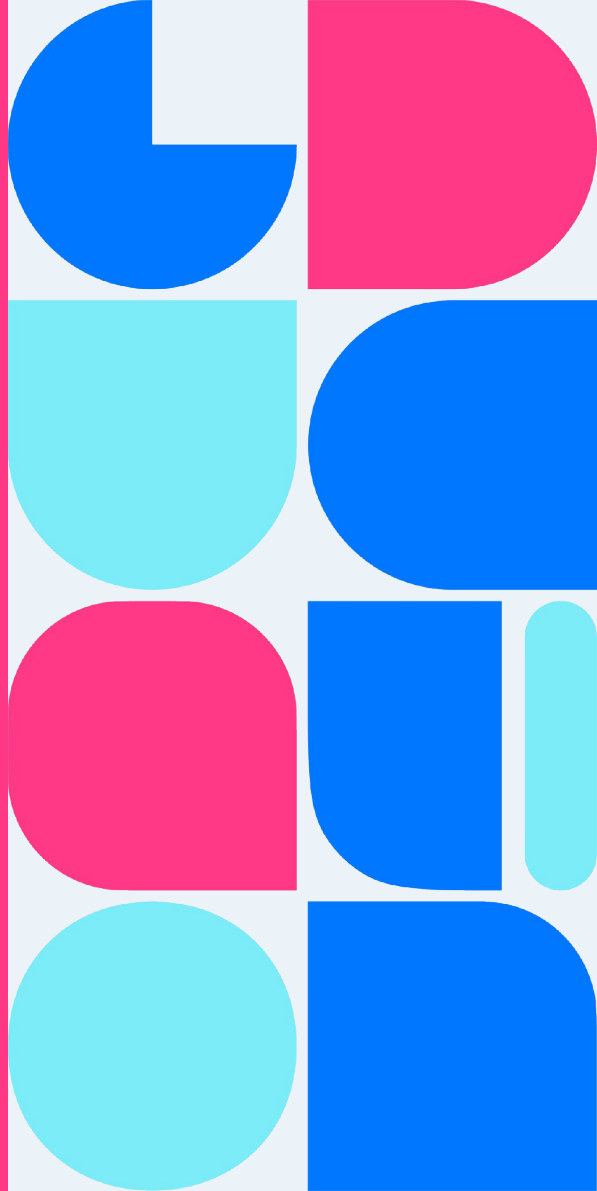
1. TF, но с насыщением (аксиома TFC2)
2. Нормировку длины (как pivoted)
3. Ноль новых параметров на запрос

Идея Робертсона

Моделировать TF смесью двух распределений Пуассона («элитные» и обычные документы). Точная формула слишком сложна, поэтому её аппроксимируют простой функцией с теми же свойствами — получается BM25

BM25 и его семейство

Самая известная формула текстового ранжирования и её расширения на зоны



Okapi BM25

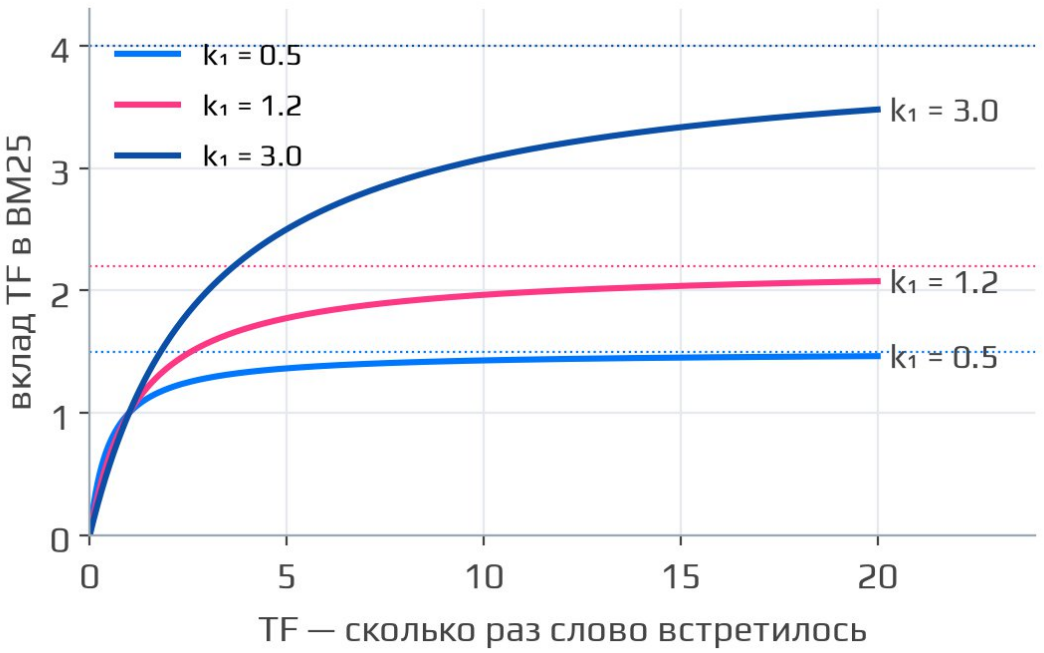
$$BM25(q, d) = \Sigma\ IDF(t) \cdot TF(t, d) \cdot (k_1 + 1)\ /\ (\ TF(t, d) + k_1 \cdot (1 - b + b \cdot |d|\ /\ avgdl)\ )$$

- BM = Best Match, 25-й вариант; система Okapi, TREC-3 (1994)
- $k_1 \approx 1.2–2.0$ — насыщение TF, $b \approx 0.75$ — нормировка длины
- IDF(t) = log (1 + (N − DF + 0.5) / (DF + 0.5)) — вариант Lucene
- Нужны только статистики коллекции: DF, длины, средняя длина
- Дефолт Lucene и Elasticsearch с 2016 года



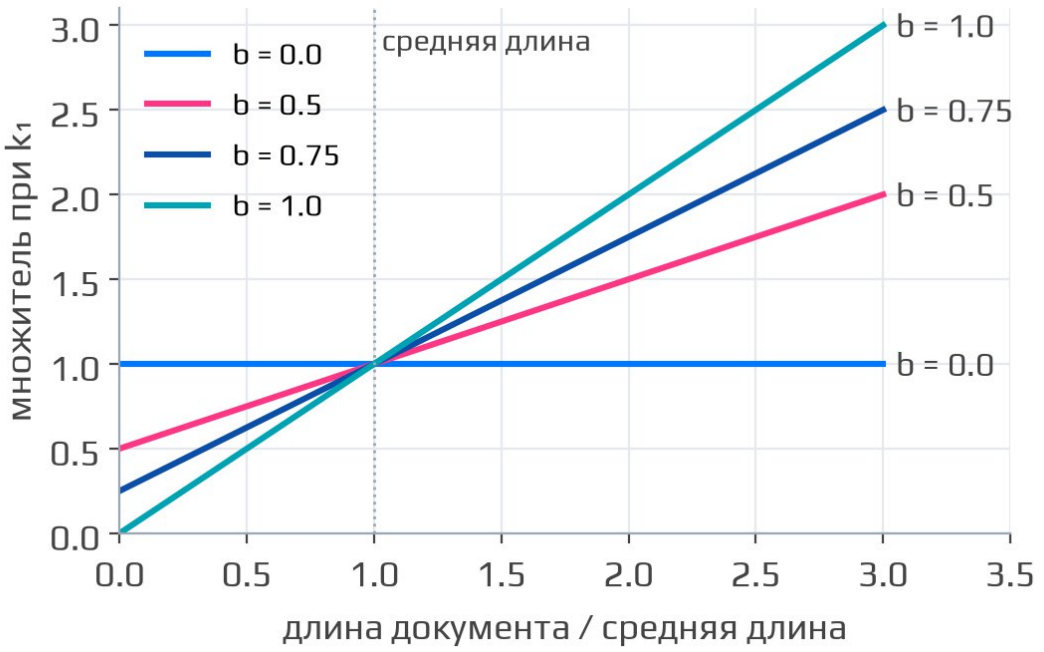
Так выглядит окапи

k_1: насыщение TF



- Вклад TF растёт, но не выше $k_1 + 1$
- $k_1 \to 0$: только факт наличия слова (как BIM)
- $k_1 \to \infty$: почти линейный TF (как сырой TF-IDF)
- Keyword stuffing больше не работает: аксиома TFC2 выполнена

b: нормировка длины



- Множитель при k_1 растёт с длиной документа: длинным труднее набрать скор
- b = 0: длина не учитывается
- b = 1: полная нормировка на длину
- Все прямые пересекаются в средней длине — это pivoted normalization из части I

Подбор k_1 и b и варианты BM25

- Дефолты k_1 = 1.2, b = 0.75 — хорошая стартовая точка
- На своих данных подбираем по сетке на валидации — это ещё не ML
- Короткие документы (заголовки) — часто меньше b
- Kamphuis et al. (ECIR 2020): 8 вариантов BM25 из статей и движков дают практически одинаковое качество

Отрицательный IDF

Классический IDF из RSV log((N − DF + 0.5)/(DF + 0.5)) отрицателен для слов, которые есть в больше чем половине документов: совпадение по стоп-слову понижает скор. Поэтому Lucene добавляет единицу под логарифмом

BM25+: нижняя граница

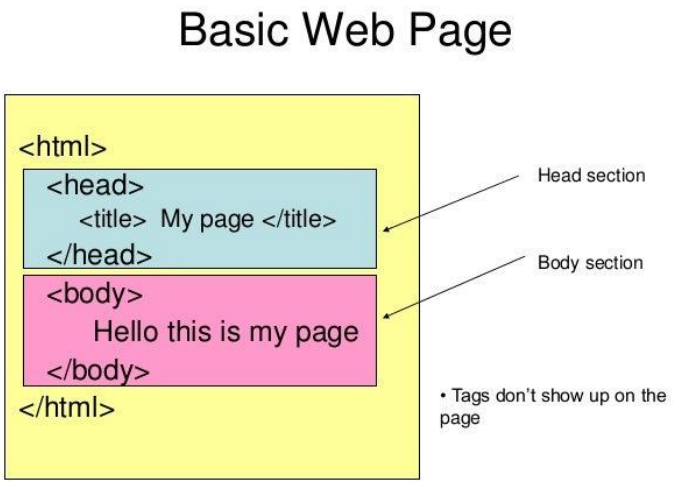
Lv & Zhai (CIKM 2011): очень длинный документ со словом запроса может проиграть короткому без него

$$\mathrm{BM25{+}}(q, d) = \Sigma\, \mathrm{IDF}(t) \cdot \left(\mathrm{TF} \cdot (k_1 + 1) \,/\, (\mathrm{TF} + k_1 \cdot (1 - b + b \cdot |d| \,/\, \mathrm{avgdl})) \;+\; \delta \right)$$

- Штраф за длину загоняет вклад TF к нулю: найденное слово почти ничего не даёт
- $\delta \approx 1$ гарантирует: наличие слова всегда даёт хоть что-то
- Lv & Zhai добавили к аксиомам из части I нижние границы TF (LB1, LB2) и нашли тот же баг у pivoted, LM Дирихле и PL2

Текстовые зоны

- Документ состоит из зон: title, body, url, anchor-текст ссылок…
- Слово в заголовке — сильный сигнал, в теле — слабее
- Зоны пишем прямо в постинги индекса
- В ДЗ 2 у документов две зоны: title и body



Зонный постинг:
итмо → [doc 3: title 1, body 2]

Как смешивать зоны

Вариант 1: склеить

1. BM25(title + body)
2. Теряем информацию о зонах

Вариант 2: смесь скоров

1. $g \cdot BM25(title) + (1 - g) \cdot BM25(body)$
2. Насыщение считается отдельно в каждой зоне

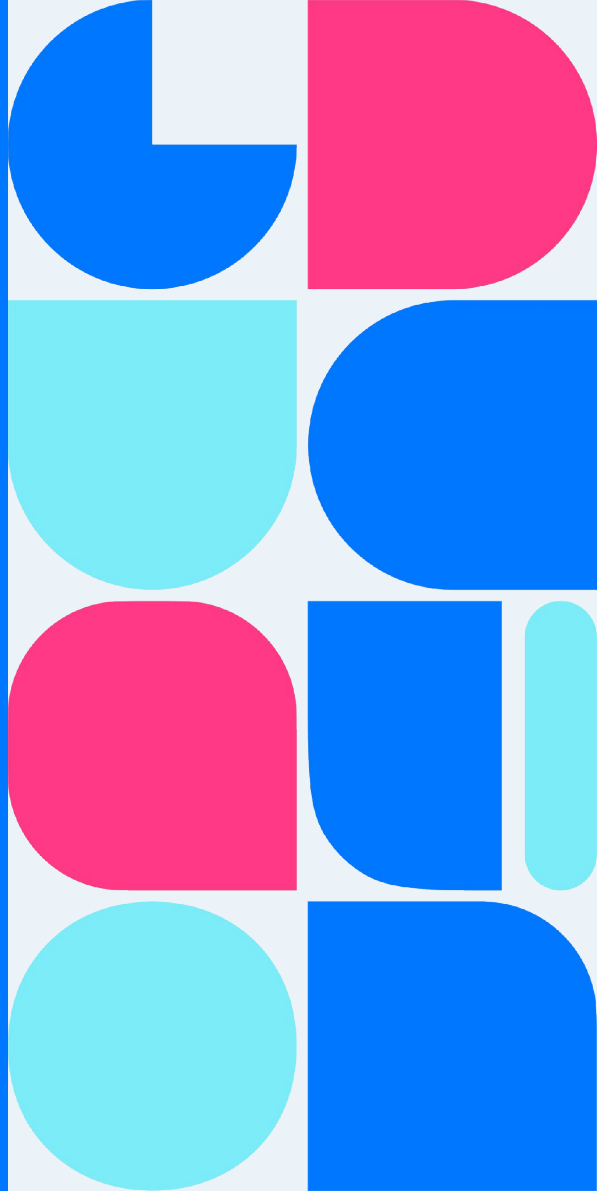
Вариант 3: BM25F (Robertson, Zaragoza, Taylor, 2004)

$$TW(t, d) = \Sigma\ w(z) \cdot TF(t, z) \,/\, (1 - b(z) + b(z) \cdot |z| \,/\, avg|z|), \quad z \text{ — зоны}$$

Сначала взвешенно складываем TF по зонам, потом один раз насыщаем: $BM25F = \Sigma\ IDF(t) \cdot TW \cdot (k_1 + 1) / (TW + k_1)$

Языковые модели для поиска

Другой вероятностный взгляд: какова вероятность, что документ «породил» запрос



Query likelihood

Ponte & Croft (SIGIR 1998): у каждого документа своя языковая модель M(d)

$$\text{Score}(q, d) = P(q \mid M(d)) = \prod P(t \mid M(d)), \quad t \in q$$

- Простейшая модель — униграммная: P(t | M(d)) = TF(t, d) / |d|
- Проблема: нет слова в документе → P = 0 → весь скор 0
- Ровно та же проблема, что в лекции 3 с биграммами запросов
- Лечение то же: сглаживание

Повторение из лекции 3

Сглаживание по коллекции

Jelinek-Mercer

$$(1 - \lambda) \cdot \mathrm{TF}/|d| \; + \; \lambda \cdot P(t \mid C)$$

интерполяция с моделью коллекции, как в лекции 3;
λ — вес коллекции (на семинаре в пт лучшее λ = 0.7)

Дирихле

$$(\mathrm{TF} + \mu \cdot P(t \mid C)) \; / \; (|d| + \mu)$$

μ ≈ 2000 для документов; для коротких пассажей меньше
(на семинаре в пт лучшее μ = 200)

Если расписать log P(q | d) с Дирихле

$$\Sigma \log(1 + \mathrm{TF} \; / \; (\mu \cdot P(t \mid C))) \; + \; |q| \cdot \log(\mu \; / \; (|d| + \mu)), \;\; t \in q \cap d$$

TF есть, IDF есть (редкое слово → маленькое P(t|C)), нормировка длины есть — TF-IDF снова выводится из вероятностей

BM25 или языковая модель?

	BM25	Query likelihood
Откуда	BIM + 2-Poisson, эвристика	языковая модель документа
Параметры	k_1, b	μ (или λ)
Качество	сопоставимо	сопоставимо
Где дефолт	Lucene, Elasticsearch, whoosh	Indri, Galago
Бонус	простая, быстрая	естественно расширяется: RM3, близость

Вывод

Две разные вероятностные истории приходят к тем же частям: насыщение TF, IDF, поправка на длину. Поэтому и качество близкое

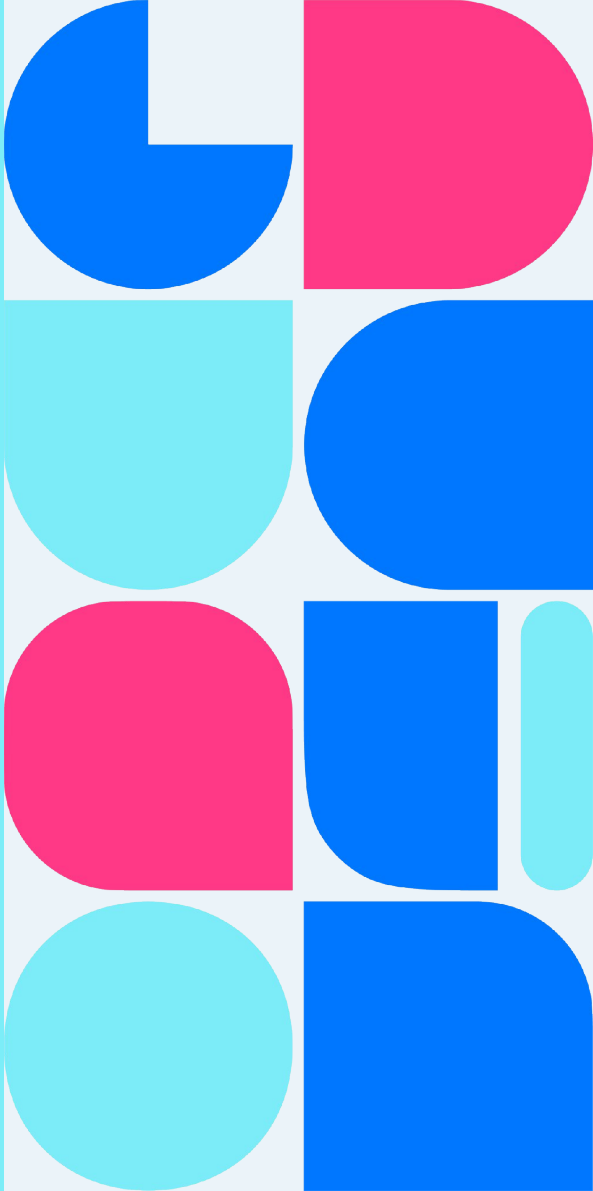
В продакшне бейзлайн — BM25; LM удобна для расширений вроде RM3

Третье семейство: DFR

Divergence from Randomness (Amati & van Rijsbergen, 2002), дефолт в Terrier. Вес слова — насколько его частота в документе выше, чем при случайном раскладе

Близость слов и пассажи

Научить ранжирование видеть, что слова запроса стоят рядом



Мешок слов, снова

«нью йорк таймс»

«…в нью-дели… из йорка… таймс…»

для BM25 оба документа почти одинаковы

- Нужны позиции слов — координатный индекс из лекции 2
- Хранить позиции дорого: индекс в разы больше
- В VK: списки docID в памяти, позиции на SSD

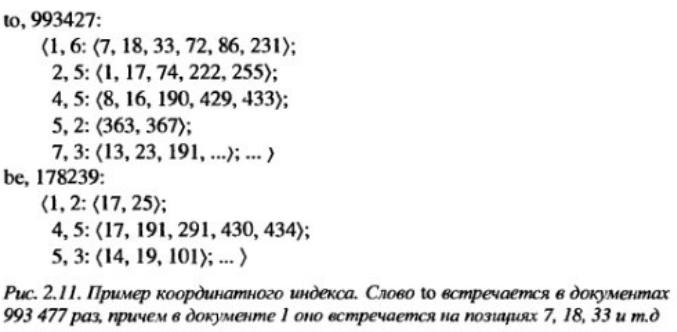

to, 993427:
⟨1, 6: ⟨7, 18, 33, 72, 86, 231⟩;
2, 5: ⟨1, 17, 74, 222, 255⟩;
4, 5: ⟨8, 16, 190, 429, 433⟩;
5, 2: ⟨363, 367⟩;
7, 3: ⟨13, 23, 191, ...⟩; ... ⟩
be, 178239:
⟨1, 2: ⟨17, 25⟩;
4, 5: ⟨17, 191, 291, 430, 434⟩;
5, 3: ⟨14, 19, 101⟩; ... ⟩

Рис. 2.11. Пример координатного индекса. Слово to *встречается в документах 993 477 раз, причем в документе 1 оно встречается на позициях 7, 18, 33 и т.д*

Координатный индекс: для каждого документа — позиции слова (Маннинг)

Повторение из лекции 2

Меры близости

- Покрывающее окно: минимальный отрезок текста, где есть все слова запроса
- Минимальное расстояние между парами слов запроса
- Бонус за правильный порядок и точное фразовое совпадение

$$\mathrm{Score}(q, d) = \mathrm{BM25}(q, d) + \log(\alpha + \exp(-\delta(q, d)))$$

δ — минимальное расстояние между словами запроса в документе

Tao & Zhai (SIGIR 2007)

Сравнили пять мер близости: лучше всех минимальное попарное расстояние, бонус должен быстро насыщаться. Но на MIRACL (семинар) бонус вредит: размеченные нерелевантные там — «трудные» пассажи со словами рядом

Пассажи

- Пассаж — кусок документа: фиксированные блоки или скользящее окно длины L
- Считаем BM25 по каждому пассажу, скор документа — лучший пассаж
- Так автоматически поднимаются документы, где слова запроса рядом
- Длинный документ перестаёт выигрывать за счёт объёма

Где ещё это нужно

1. BERT видит только 512 токенов: MaxP — лучший пассаж (Dai & Callan, 2019)
2. RAG и генеративный ответ ранжируют пассажи, а не документы (лекция 1)

Собираем ручную формулу

$$\text{Score} = w_1 \cdot \text{BM25F} + w_2 \cdot \text{BestPassage} + w_3 \cdot \text{Proximity} + \ldots$$

- Так работали поисковики до машинного обучения: в Поиске Mail.ru такая формула жила до 2012 года
- Каждый новый сигнал — новый вес, подбирать руками всё сложнее
- Сотни признаков — только машинное обучение ранжированию (лекция про LTR)
- BM25, BM25F, близость становятся признаками для LTR

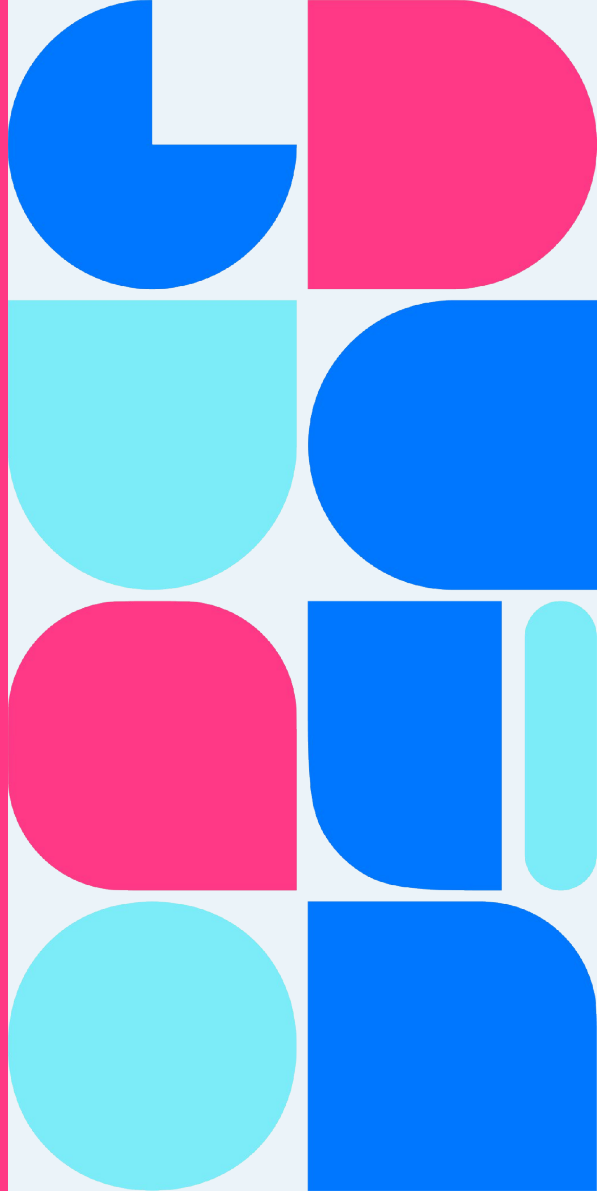
В ДЗ 2 (пт) ручная формула из нескольких текстовых скоров с подбором весов — законный способ побить бейзлайн

Итоги

- ✓ Градуированная релевантность: DCG / nDCG; бинарная: MAP, MRR. Разметка шумная, неразмеченное ≠ нерелевантное, разницу проверяем парным тестом
- ✓ PRP: сортировать по $P(R = 1 \mid q, d)$. BIM → RSV → IDF с логарифмом
- ✓ BM25 = IDF × насыщенный TF × нормировка длины. $k_1 \approx 1.2$, $b \approx 0.75$
- ✓ BM25F: складываем TF по зонам с весами, насыщаем один раз. BM25+ чинит длинные документы
- ✓ Query likelihood с Дирихле — ещё один вывод TF-IDF из вероятностей
- ✓ Близость и пассажи учитывают порядок слов и превращают скоры в признаки для LTR

Домашнее задание 2

Текстовое ранжирование: контест на Kaggle



ДЗ 2: текстовое ранжирование

- Датасет VK MARCO: реальные запросы и документы с зонами title и body
- Контест на Kaggle, ссылка — в чате курса
- Нужно переранжировать документы по запросам, используя только тексты
- Бейзлайн: TF-IDF по склейке title + body

Можно	Нельзя
1 TF-IDF, BM25, BM25F, LM, близость — своими руками	1 Готовые ранжирующие библиотеки (rank-bm25, bm25s…)
2 Лемматизация, стемминг, стоп-слова	2 ML за рамками подбора коэффициентов
3 Подбор нескольких коэффициентов по сетке	3 Нейросети

ДЗ 2: сдача и оценивание

1. Побить бейзлайн на Kaggle
2. Оформить решение в solution.py: ./solution.py --submission_file=submission.csv DATA_DIR
3. Зафиксировать окружение в requirements.txt, решение должно воспроизводиться на Linux
4. Сдать через репозиторий курса (Merge Request)

Баллы (из 10)	Условие
0	бейзлайн не побит — задание возвращается на доработку
4	бейзлайн побит на Kaggle
10	бейзлайн побит и соблюдены все требования: solution.py, воспроизводимость, окружение

Материалы

Почитать

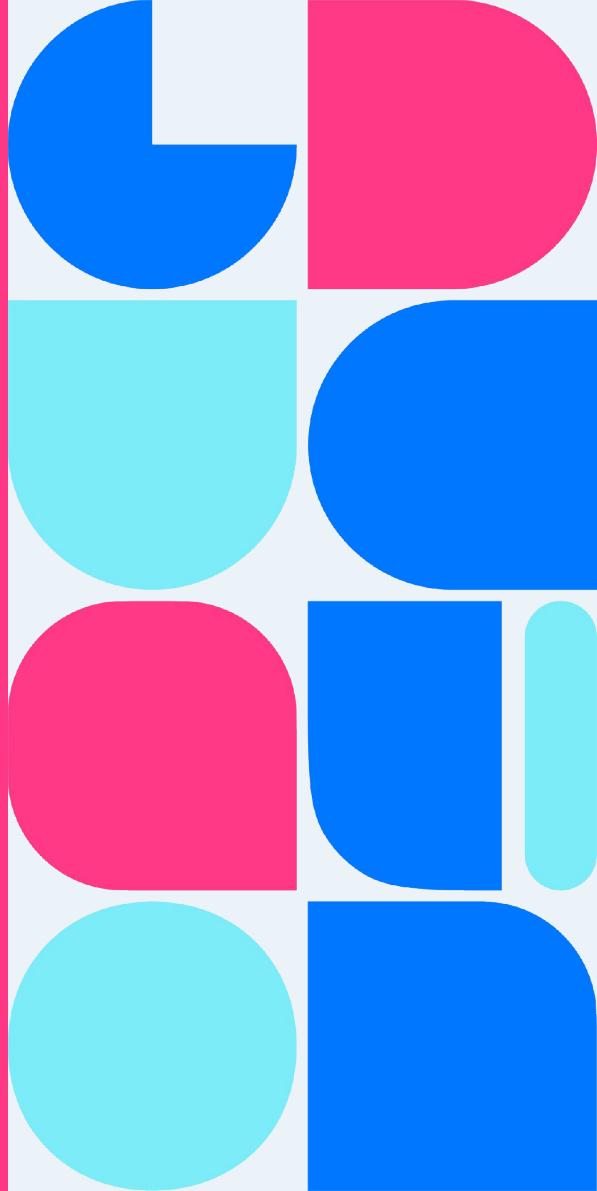
1. Маннинг и др.: гл. 8 (метрики), 11 (вероятностные модели), 12 (языковые модели)
2. Büttcher, Clarke, Cormack. Information Retrieval: гл. 8 (BM25), 12 (оценка)
3. Robertson, Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond, 2009
4. Zhai, Lafferty. A Study of Smoothing Methods for LMs Applied to IR, SIGIR 2001

Потрогать руками

1. whoosh: scoring.BM25F — на деле смесь BM25 по полям (см. семинар)
2. bm25s: быстрый BM25 на NumPy (не для ДЗ)
3. Pyserini: BM25, RM3, QL с Дирихле из коробки
4. ir-measures / ranx: MAP, nDCG, judged@k
5. Kamphuis et al. Which BM25 Do You Mean?, ECIR 2020

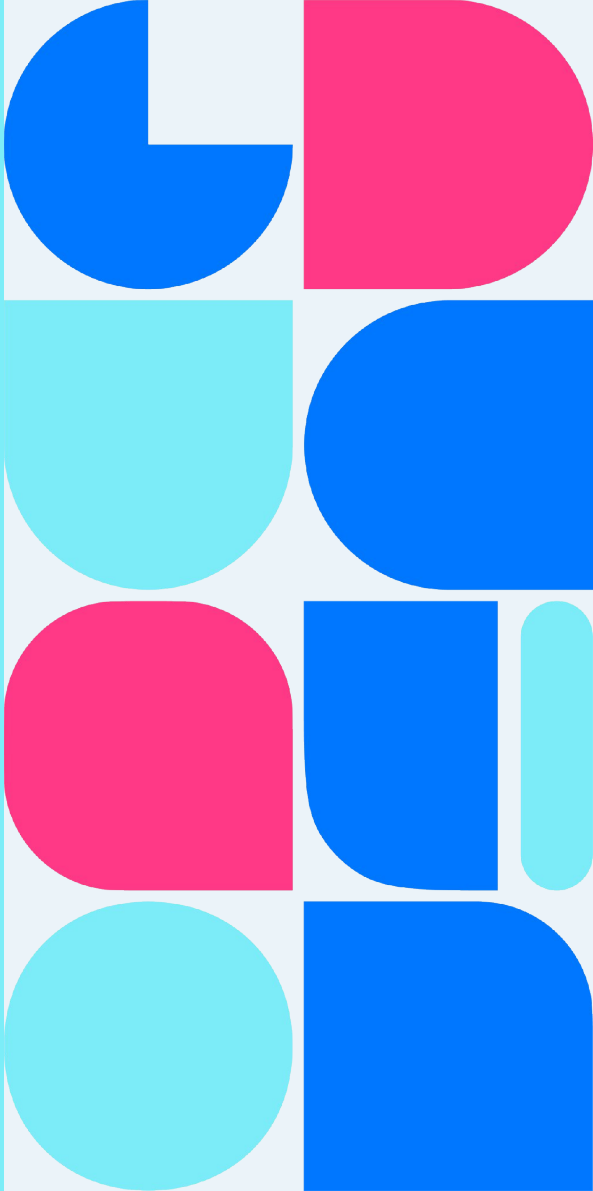
Перерыв

10 минут, потом семинар



Семинар

BM25 руками и подбор k_1 и b, BM25F по зонам, языковые модели, близость слов, nDCG и MAP на MIRACL ru





Спасибо
за внимание!

Руслан Аллаяров

education