education

Поведенческое и ссылочное ранжирование

Информационный поиск и ранжирование

Николай Трофимов

ML-инженер в команде качества поиска



education

Цель занятия

Понять, как ссылочные и поведенческие факторы влияют на ранжирование, и научиться объяснять принцип работы PageRank

Ссылочное ранжирование

Что можно использовать кроме текста ?

Текст – действительно важный источник информации при ранжировании. Но только по тексту нельзя сказать насколько документ является авторитетным и его необходимо ставить на высокие позиции

Что есть кроме тела документа ? Ссылки

Возникают вопросы

- Достаточно ли ссылки авторитетны ?
- Они полезны для ранжирования ?



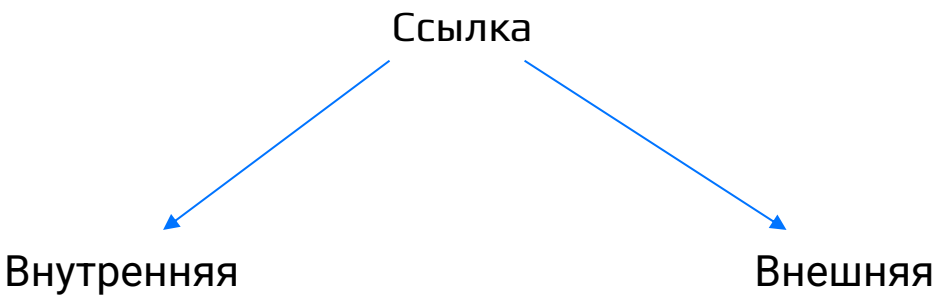
Что такое ссылка?

Гиперссылка — часть гипертекстового документа, ссылающаяся на элемент в этом документе или на другой объект, расположенный на локальном диске или в компьютерной сети (Википедия)

В HTML-разметке тэг <a> определяет гиперссылку для перехода на определённое место страницы

```
<a href="https://example.com">Website</a>
```

Какие бывают?



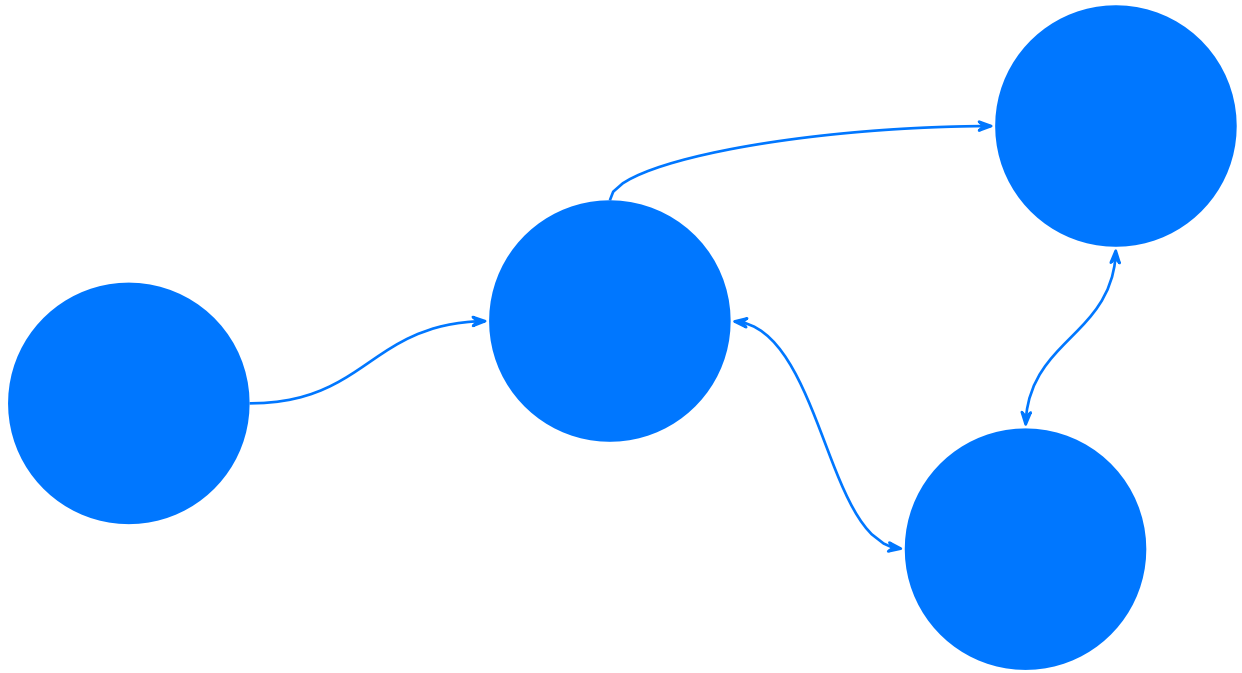
Ссылочный граф

Сколько вершин?

- На 2023 год — около 2 млрд сайтов
- Документов — примерно на 3 порядка больше (~2 трлн)

Сколько рёбер?

- В 10 раз больше, чем вершин
- Внутренних ссылок в 5 раз больше, чем внешних



Гипотезы

Мы хотим использовать эти связи для ранжирования документов.
Первое, что приходит в голову, сказать что ресурс бывает: авторитетный или не авторитетный (бинарное значение)

Тогда выдвинем следующие гипотезы для ранжирования страниц:

1) Чем больше ссылок со страницы, тем лучше?
2) Чем больше ссылок на страницу, тем лучше?

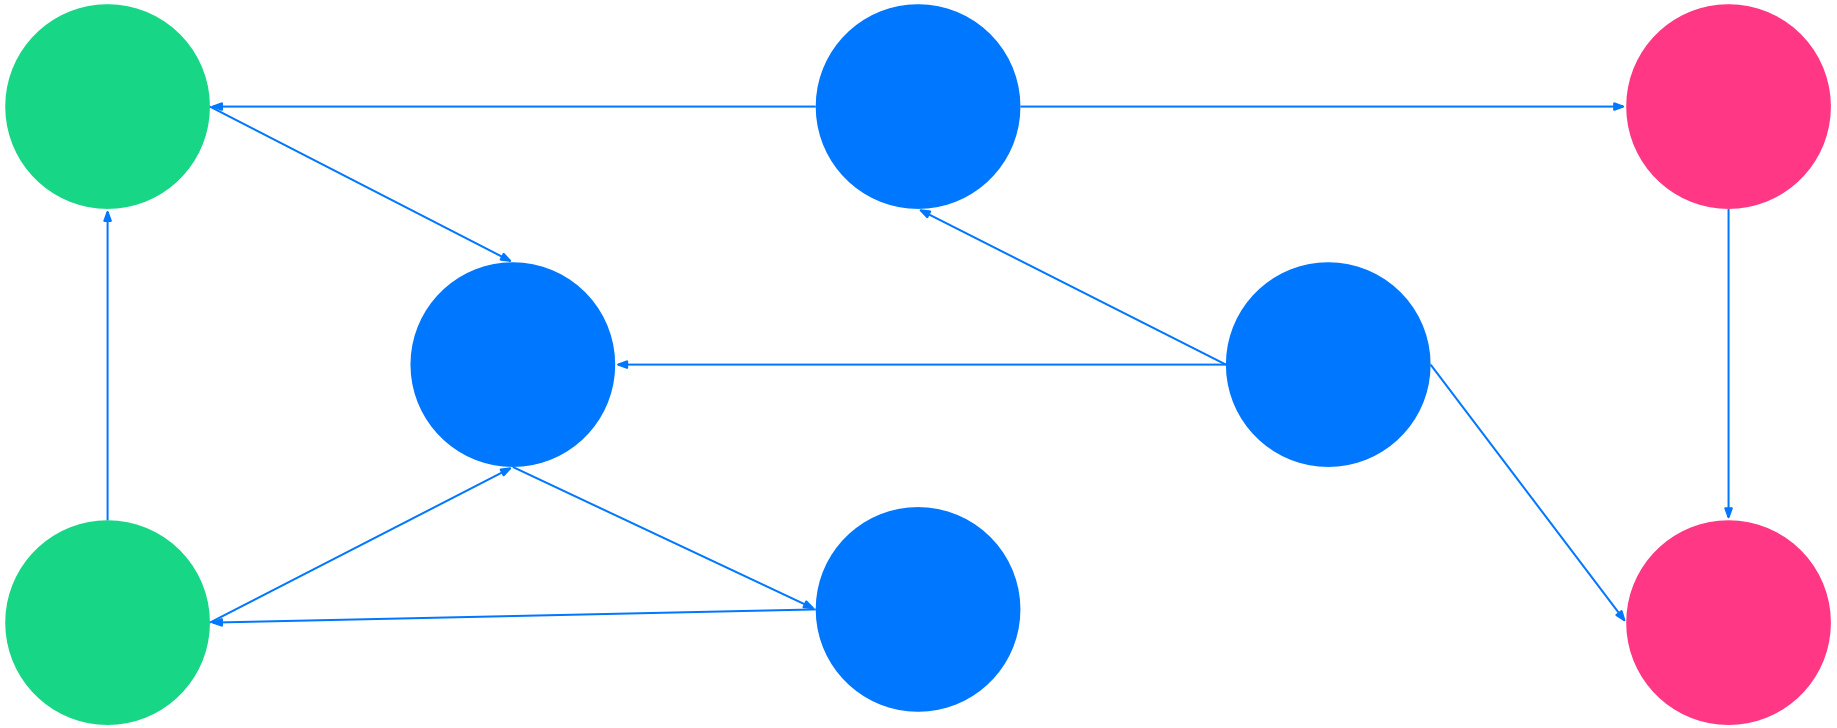
Как вы думаете, верны ли эти гипотезы?



Простой итеративный алгоритм

Сайты: хорошие, плохие, неизвестные

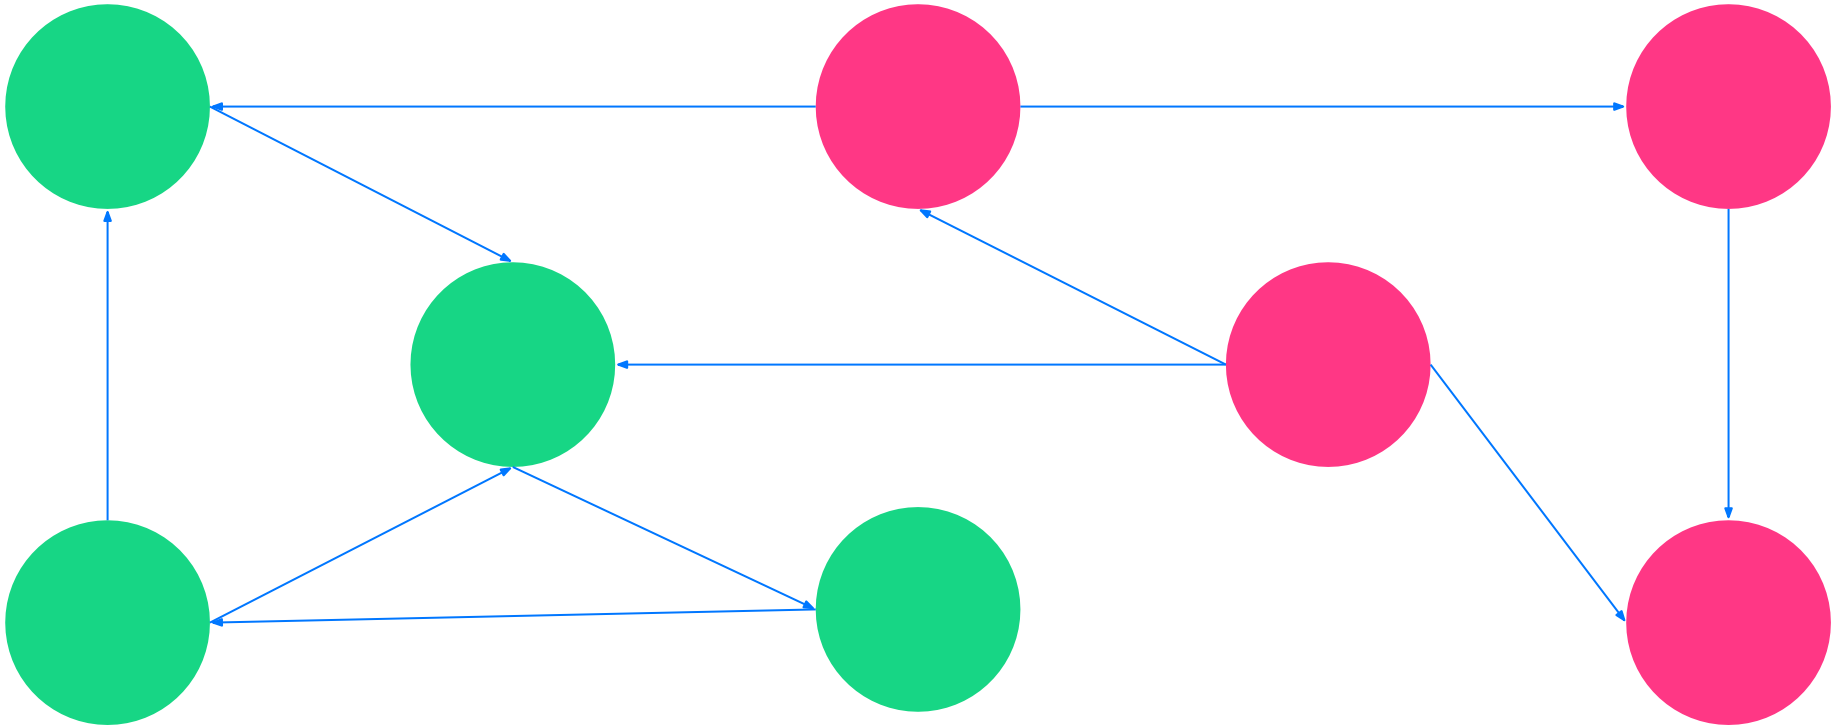
1) Если ваш сайт ссылается на плохой — ваш сайт плохой
2) Если хороший сайт ссылается на ваш — ваш сайт хороший



Простой итеративный алгоритм

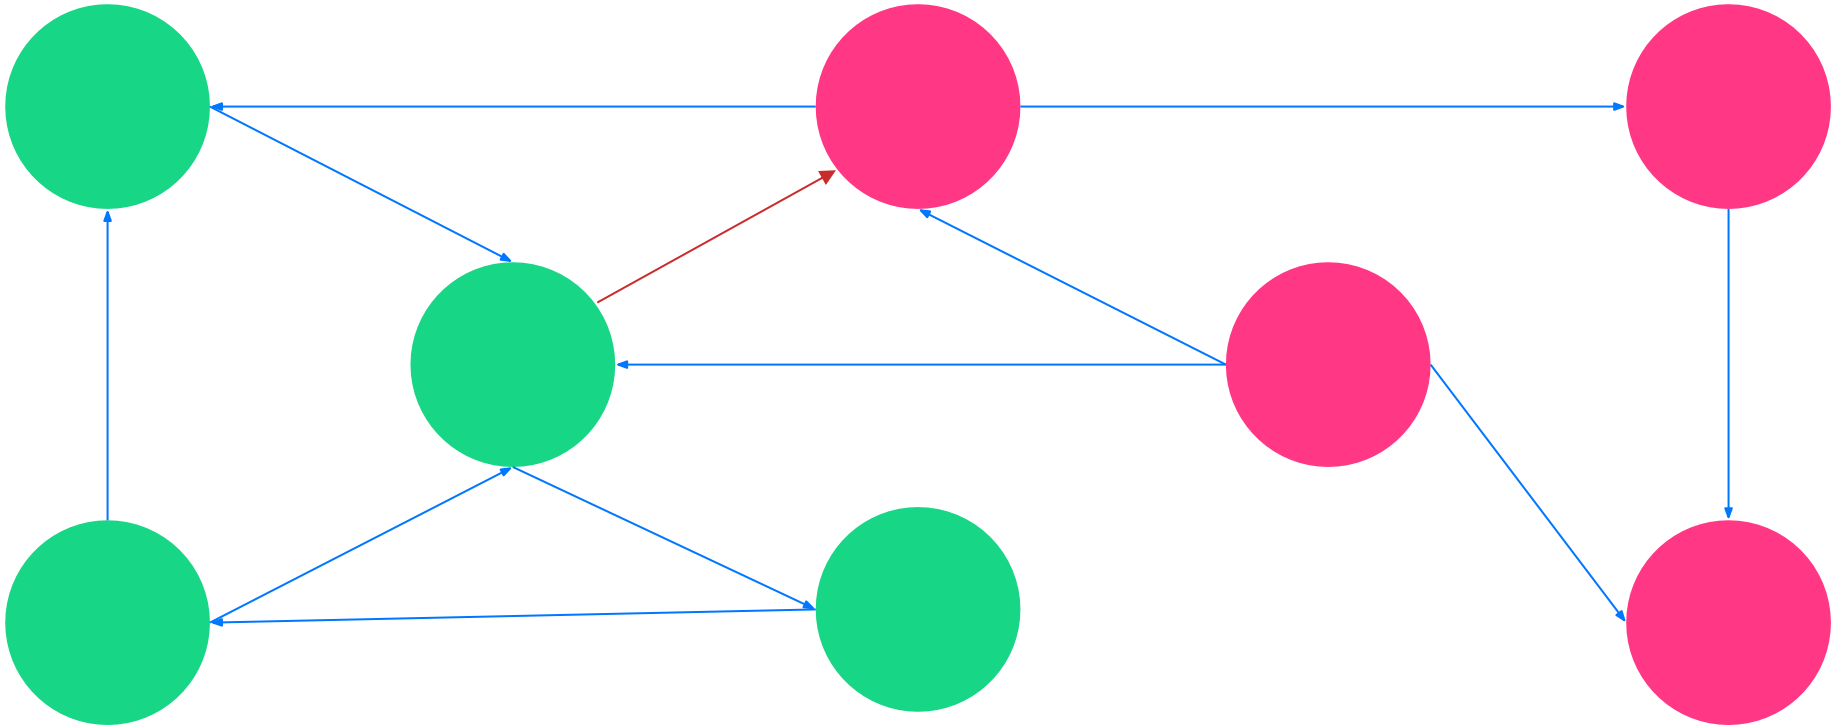
Сайты: хорошие, плохие, неизвестные

- Если ваш сайт ссылается на плохой — ваш сайт плохой
- Если хороший сайт ссылается на ваш — ваш сайт хороший
- Что, если хороший сайт ссылается на плохой?



Простой итеративный алгоритм

Из этого следует, что начальное предположение о том, что сайт бывает только либо авторитетный, либо не авторитетный ошибочна.
Необходима система, основанная на теории вероятности. Тогда бы, мы смогли воспринимать авторитетность как вероятность



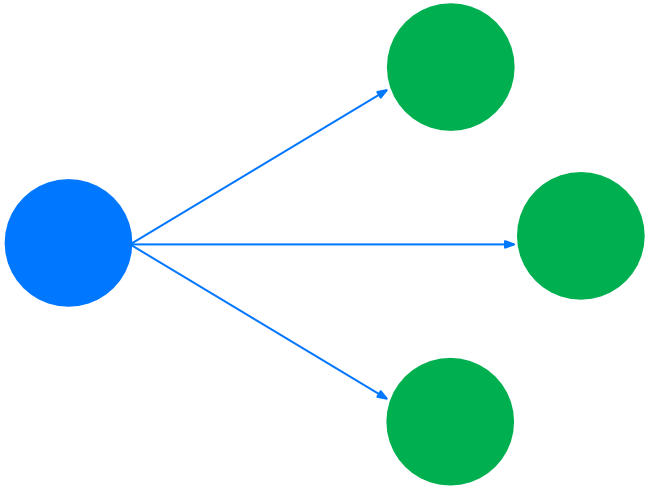
Hyperlink-Induced Topic Search (HITS)

Выделяется два типа страниц:

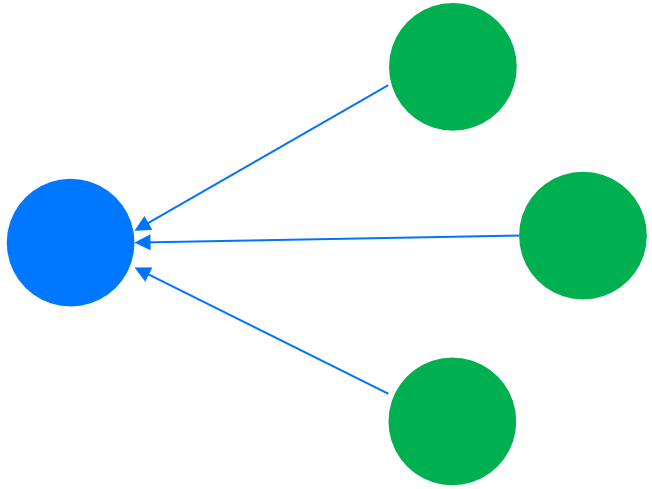
1) Авторитетная – страница, обладающая качественным контентом
2) Хаб (каталог) – страница, которая ссылается на авторитетные страницы

Алгоритм построен на гипотезах

1) Хороший хаб ссылается на хороших авторитетов
2) Хороший авторитет имеет ссылки с хороших хабов



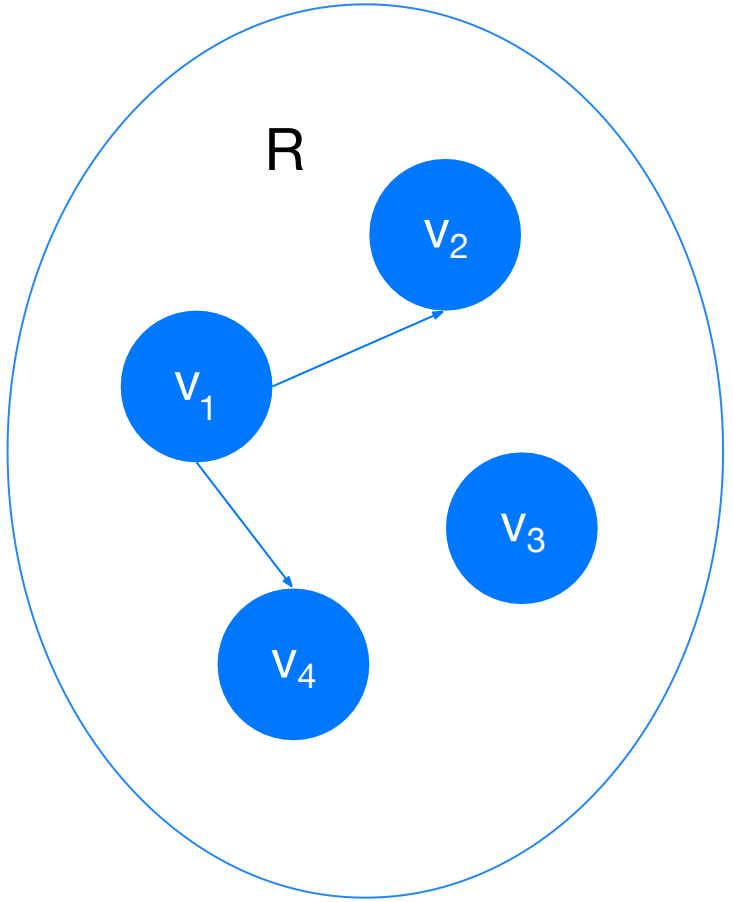
Хороший хаб



Хороший авторитет

Алгоритм

Шаг 1. Формируем начальное множество узлов **R** (например R=результат поиска)

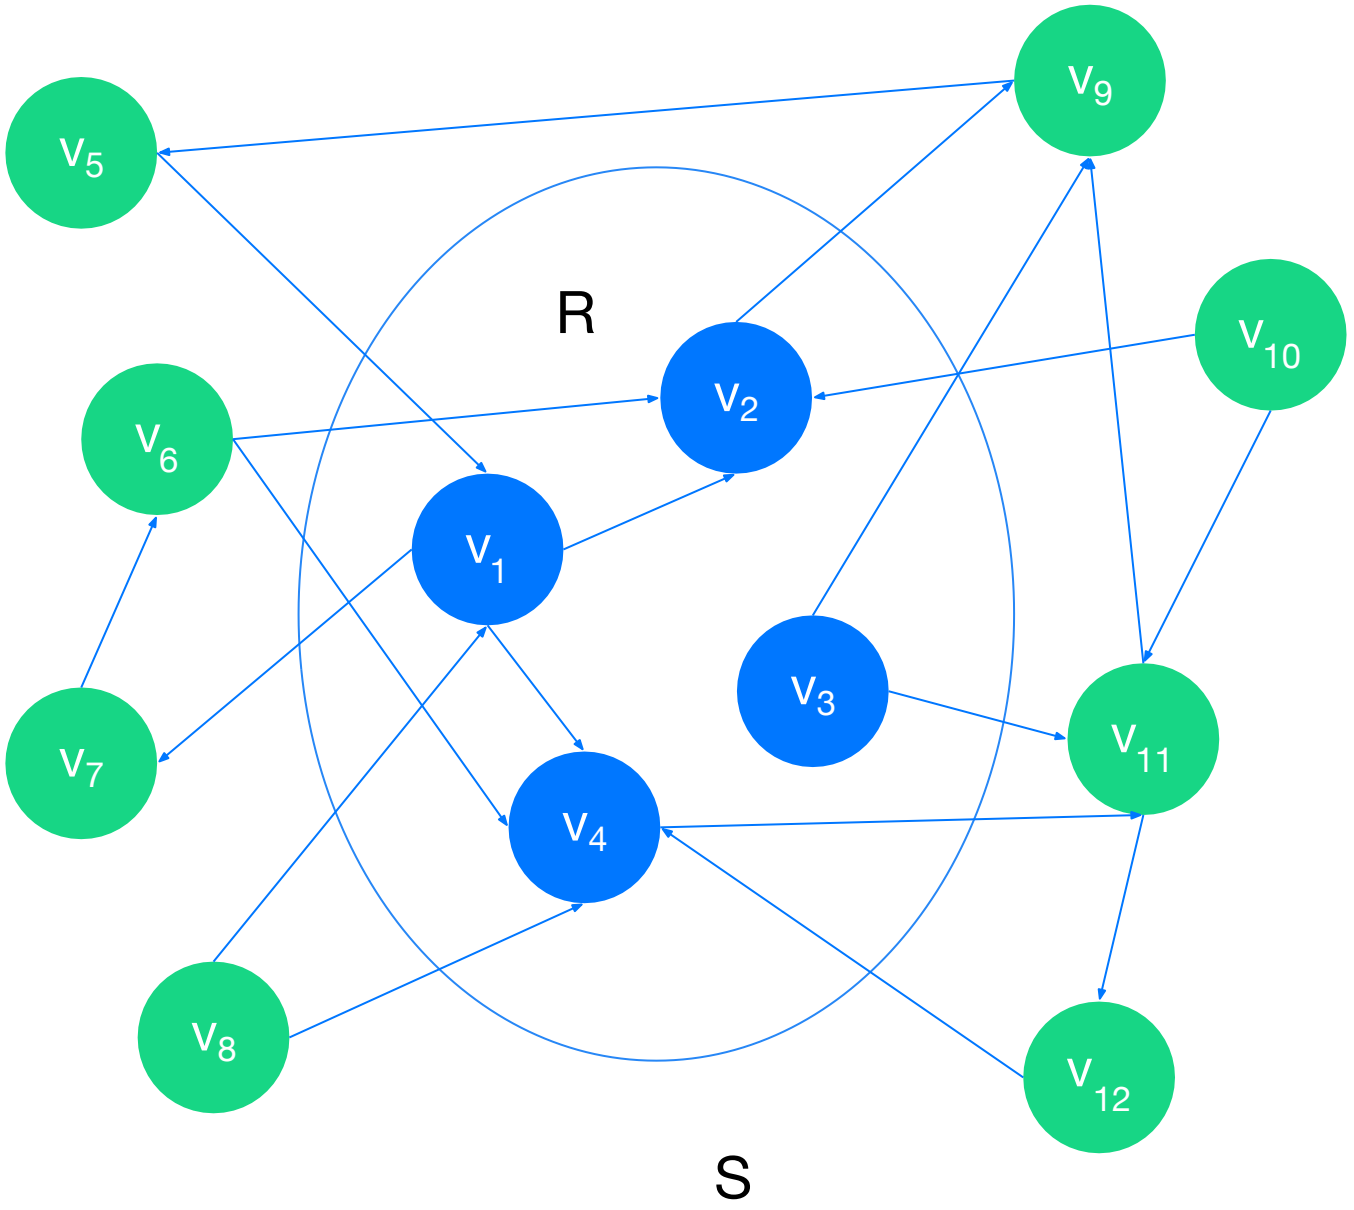


Алгоритм

Шаг 2. Расширяем его до множества **S**, добавляя документы, связанные с документами из **R** ссылками

Шаг 3. Инициализируем д ля каждой вершины v:

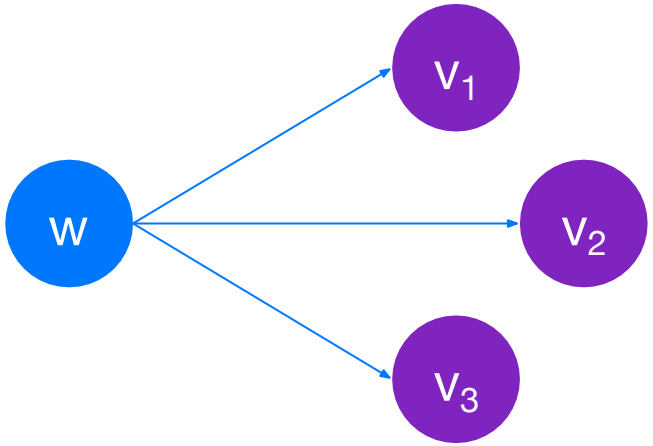
- меру «хабовости” := h(v) = 1
- меру “авторитетности» := a(v) = 1



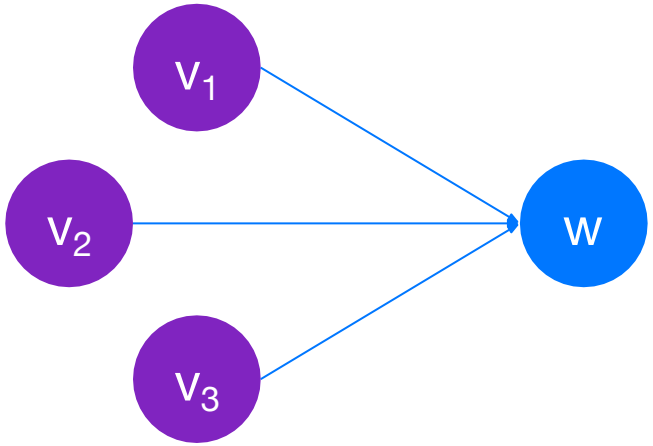
Алгоритм

Шаг 4. Повторяем несколько раз:

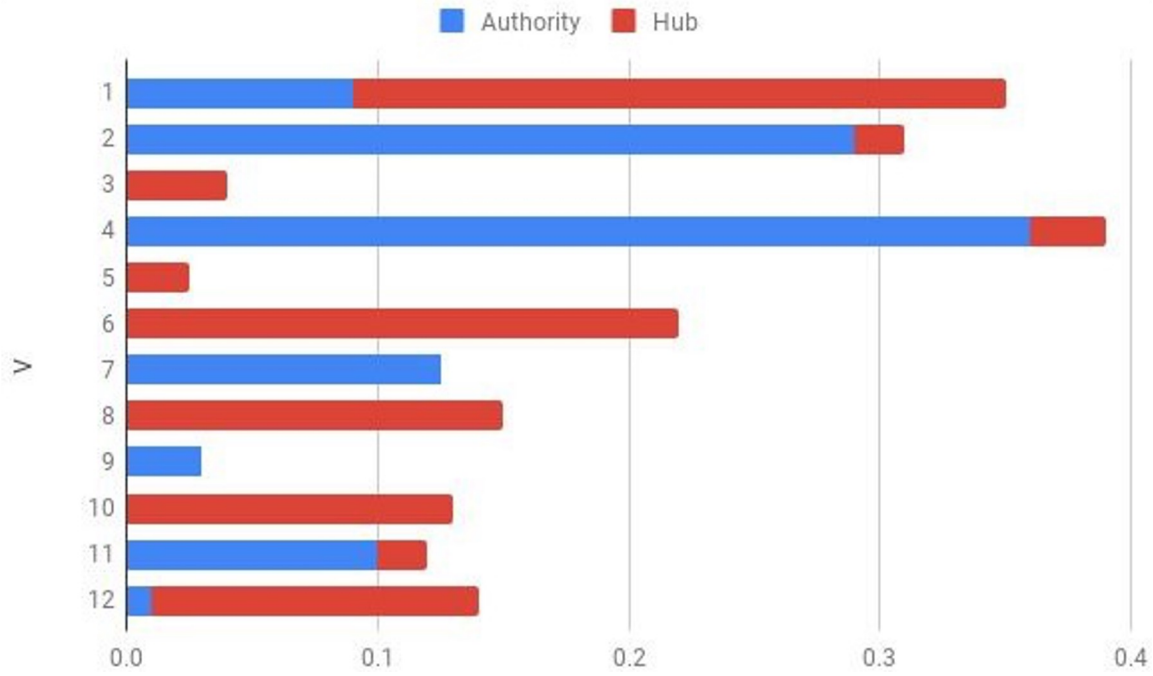
$$h(w) = \Sigma a(v_k)$$

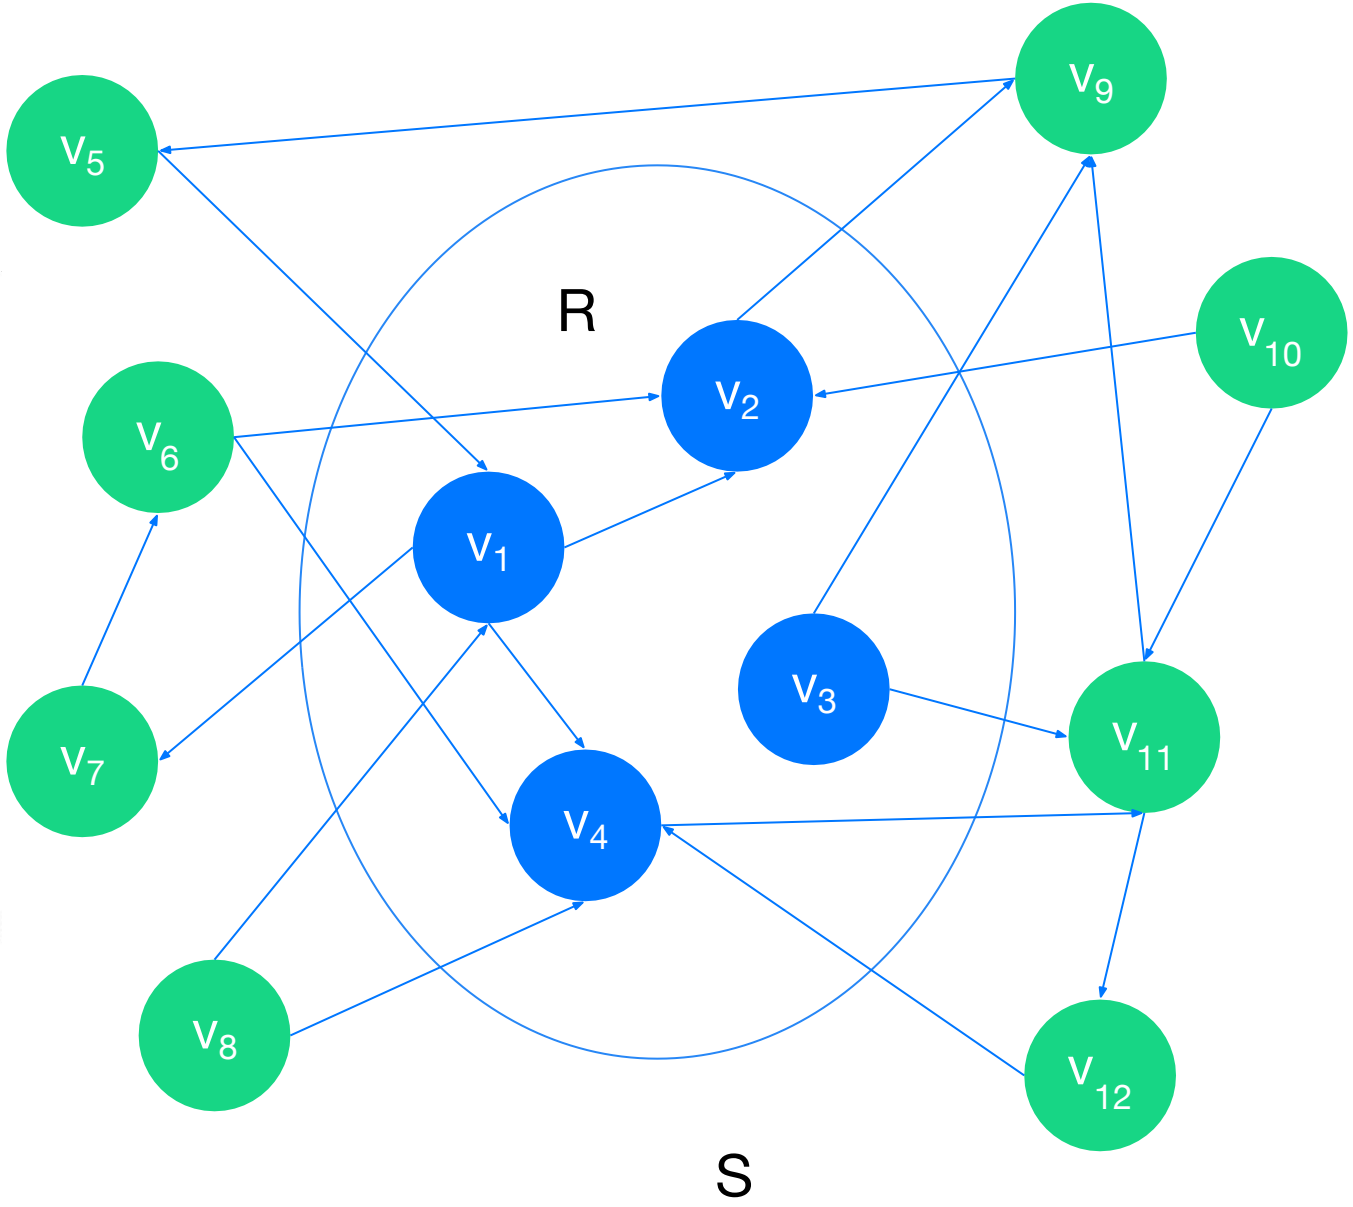


$$a(w) = \Sigma h(v_k)$$



Результат


Authority
Hub
v
1
2
3
4
5
6
7
8
9
10
11
12
0.0
0.1
0.2
0.3
0.4


v5
v9
R
v10
v2
v6
v1
v3
v7
v11
v4
v8
v12
S

На практике

Как работает алгоритм на практике:

1) Сначала по текстовой релевантности строится root set R.
2) Затем он расширяется непосредственными входящими и исходящими соседями, образуя base set S.
3) На графе S запускается HITS, который вычисляет authority и hub оценки страниц.
4) Эти оценки могут использоваться вместе с текстовой релевантностью для окончательного ранжирования.

Например финальный скор учитывающий текстовую релевантность, хаб оценку, авторитетную оценку может быть таким.

Score = 0.7 * Text_rel + 0,25 * Authority_score + 0,05 * hub_score

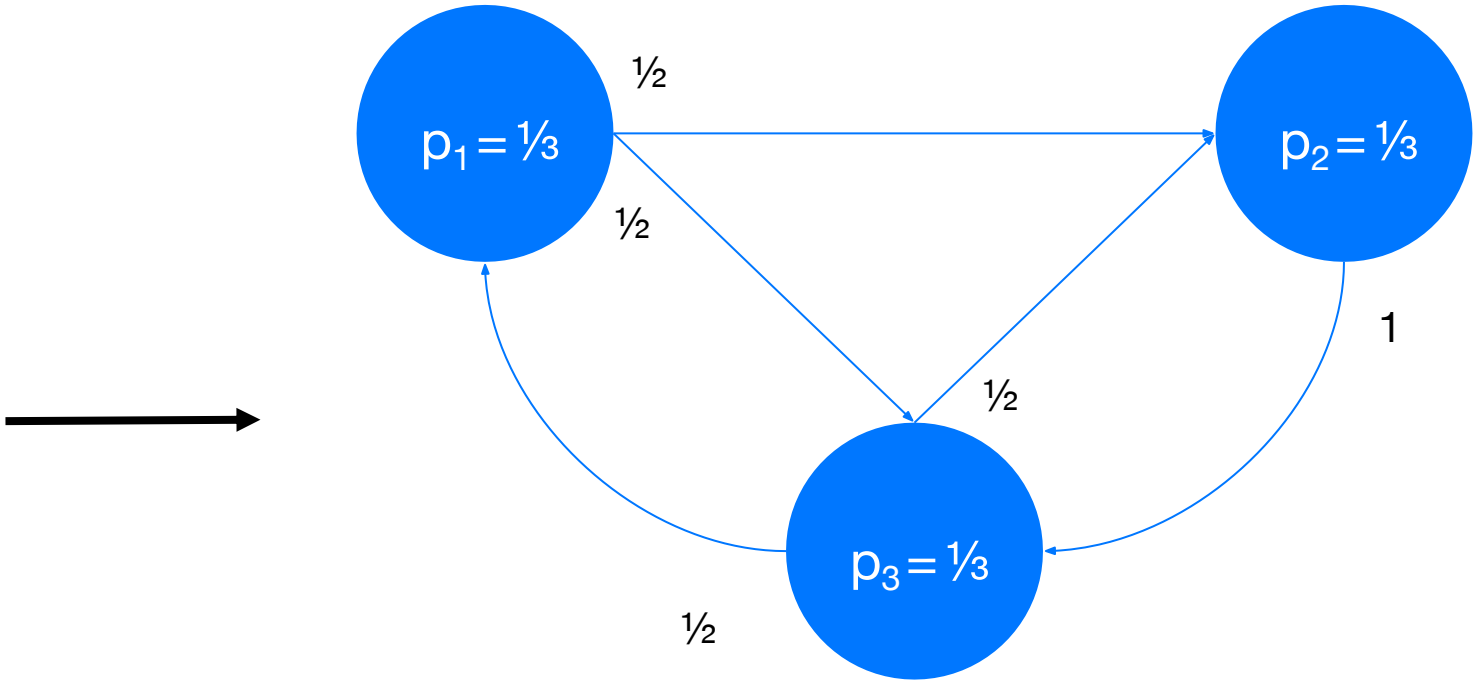
PageRank

PageRank

PageRank это алгоритм основанный на модели случайного блуждателя, в основе этой модели лежат следующие гипотезы:

- Старт с произвольной ноды (документа)
- На каждом шаге по какой-нибудь ссылке совершается переход
- Все переходы равновероятны

Пример графа с документами (вершина - документ, вероятность в нём — вероятность туда попасть сначала), на рёбрах указана вероятность перехода из конкретного документа в другой



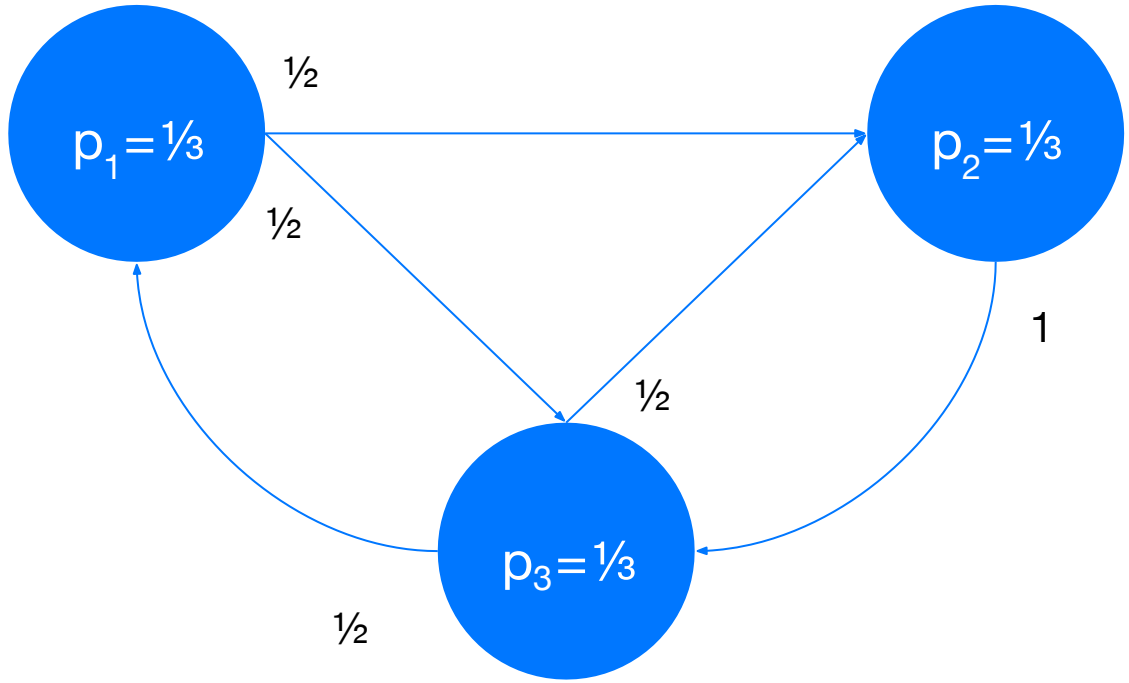
Первый переход

$p_1 = 1/3 * 1/2 = 1/6$

$p_2 = 1/3 * 1/2 + 1/3 * 1/2 = 1/3$

$p_3 = 1/3 * 1/2 + 1/3 * 1 = 1/2$

Видим, что вероятности попасть в конкретный документ (вершину) изменились после первого перехода по ссылкам

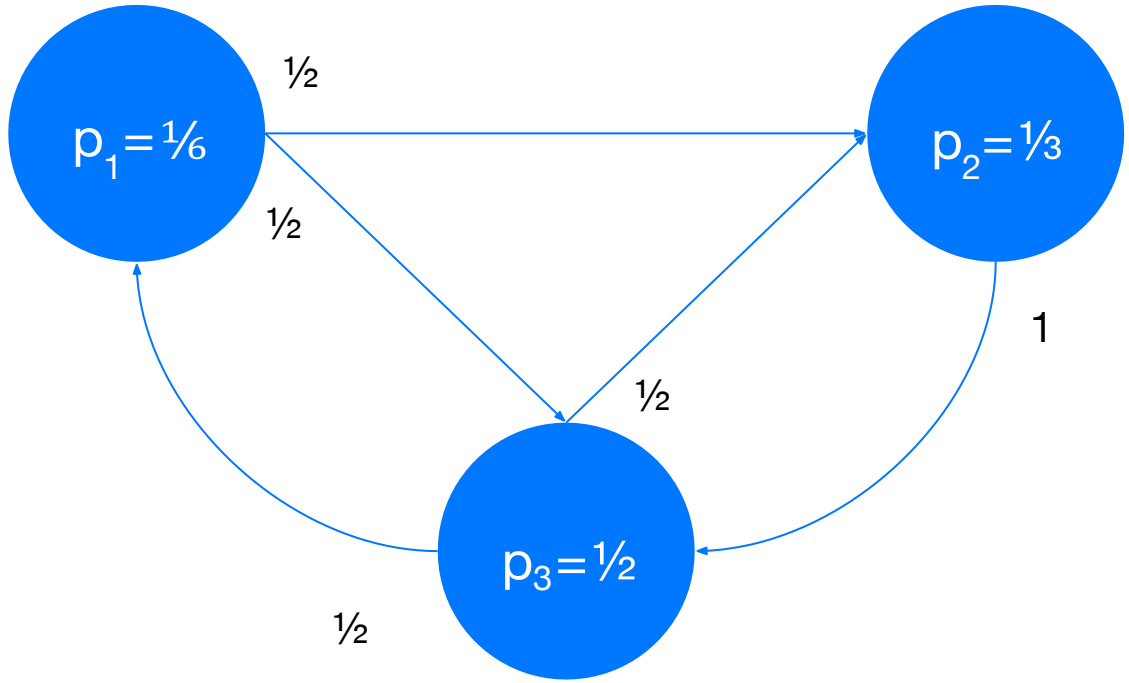


Второй переход

$p_1 = ½ * ½ = ¼$

$p_2 = ½ * ½ + ⅙ * ½ = ⅓$

$p_3 = ⅙ * ½ + ⅓ * 1 = ⅝$



Формализация. Связь с матрицей переходов

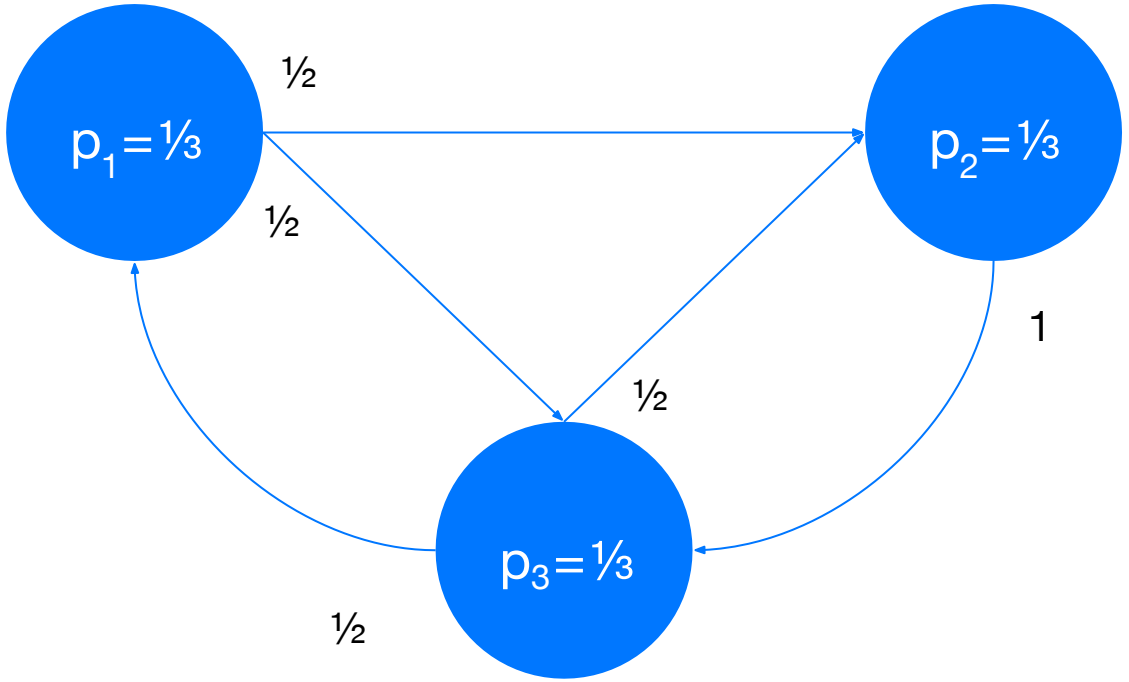
Обозначение
T-момент времени (итерация алгоритма с 0)
X_t - случайная величина, обозначающая вершину, в которой находится пользователь в момент времени t
$p^{(t)}$ - вектор состояния в момент времени t
P – это матрица переходов
P_{ij}— вероятность перейти из вершины j в вершину i
$P_{ij} = \Pr(X_{t+1} = i | X_t = j)$

Основные свойства матрицы переходов
1) $0 \leq P_{ij} \leq 1$
2) $\sum_{i=1}^{n} P_{ij} = 1$

Утверждение – 1 шаг блуждания ⇔ умножению на матрицу переходов

$p^{(t+1)} = P \quad p^{(t)}$

$$P = \begin{pmatrix} 0 & 0 & ½ \\ ½ & 0 & ½ \\ ½ & 1 & 0 \end{pmatrix} \qquad p^{(0)} = \begin{pmatrix} ⅓ \\ ⅓ \\ ⅓ \end{pmatrix}$$



Определение

Определим PageRank как

$$\text{PageRank} := \lim_{t \to \infty} p^{(t)}$$

При устремлении получим что p – собственный вектор матрицы P
p= $P \quad p$

Определим стационарное распределение цепи Маркова – это такое распределение вероятности которое не меняется с течением времени

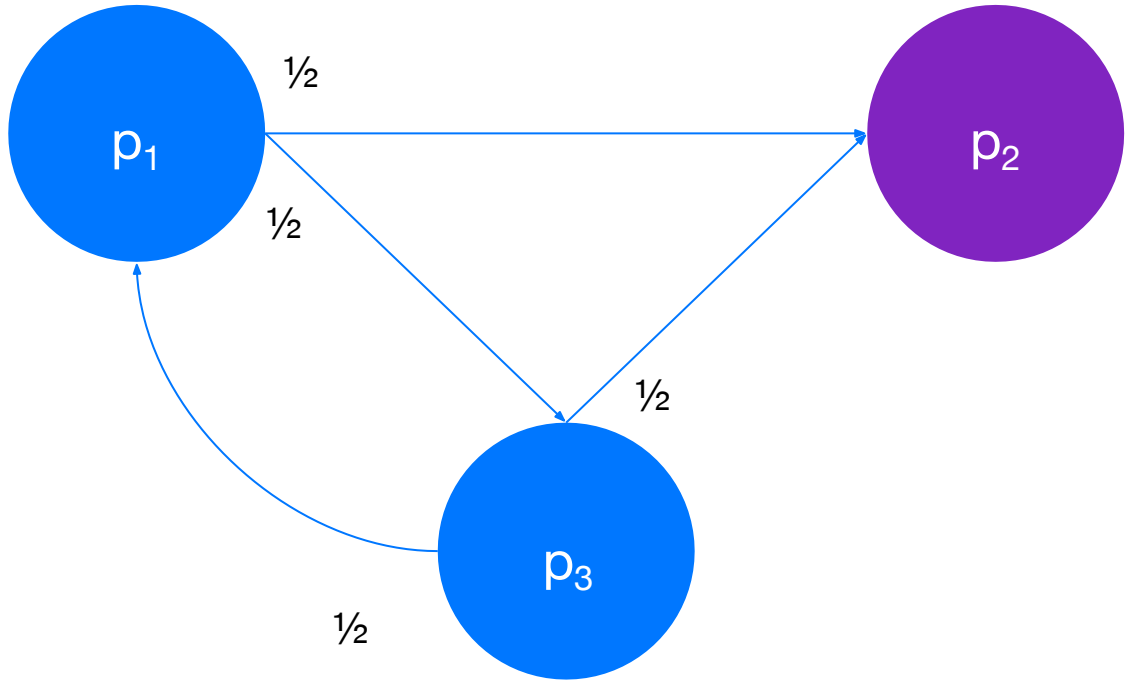
Эргодическая теорема: Если для цепи маркова выполняются следующие условия
1) Цепь неразложима — из любого состояния можно перейти в какое-то другое
2) Цепь непериодическая — состояния не меняются последовательно по циклу
=> существует **ровно одно** стационарное распределение

Висячие узлы

Причины:

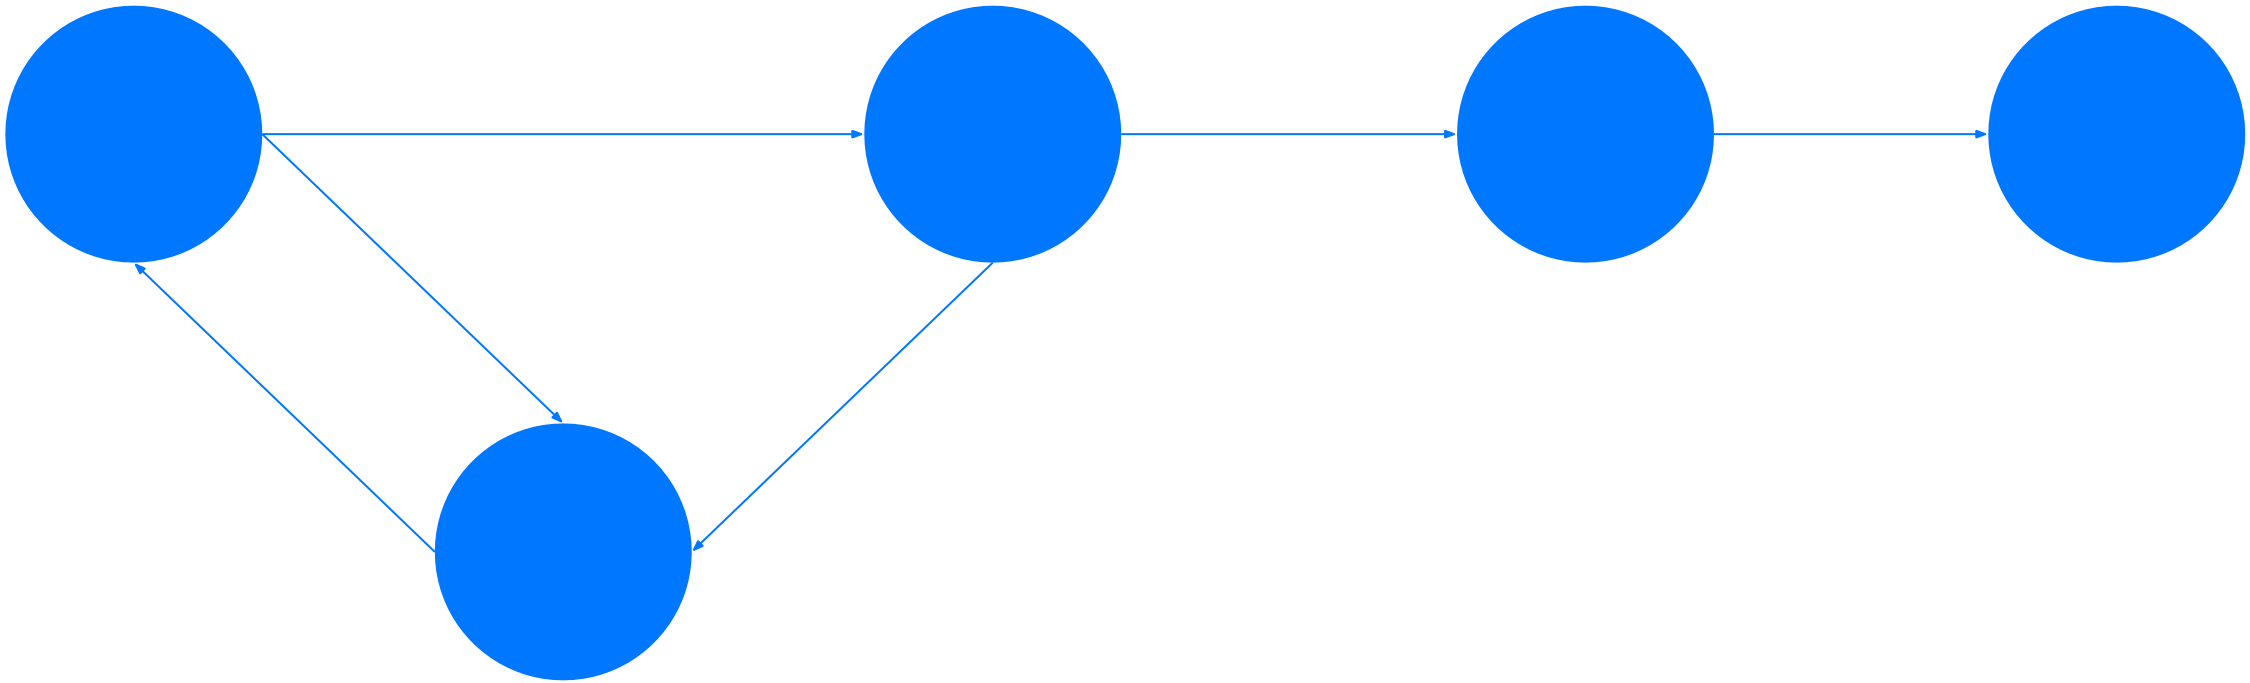
1. На странице нет ссылок
2. Страницу не обкачали (т.е. не прошли по ее ссылкам)

Проблема: не существует стационарного распределения при висячих вершинах.



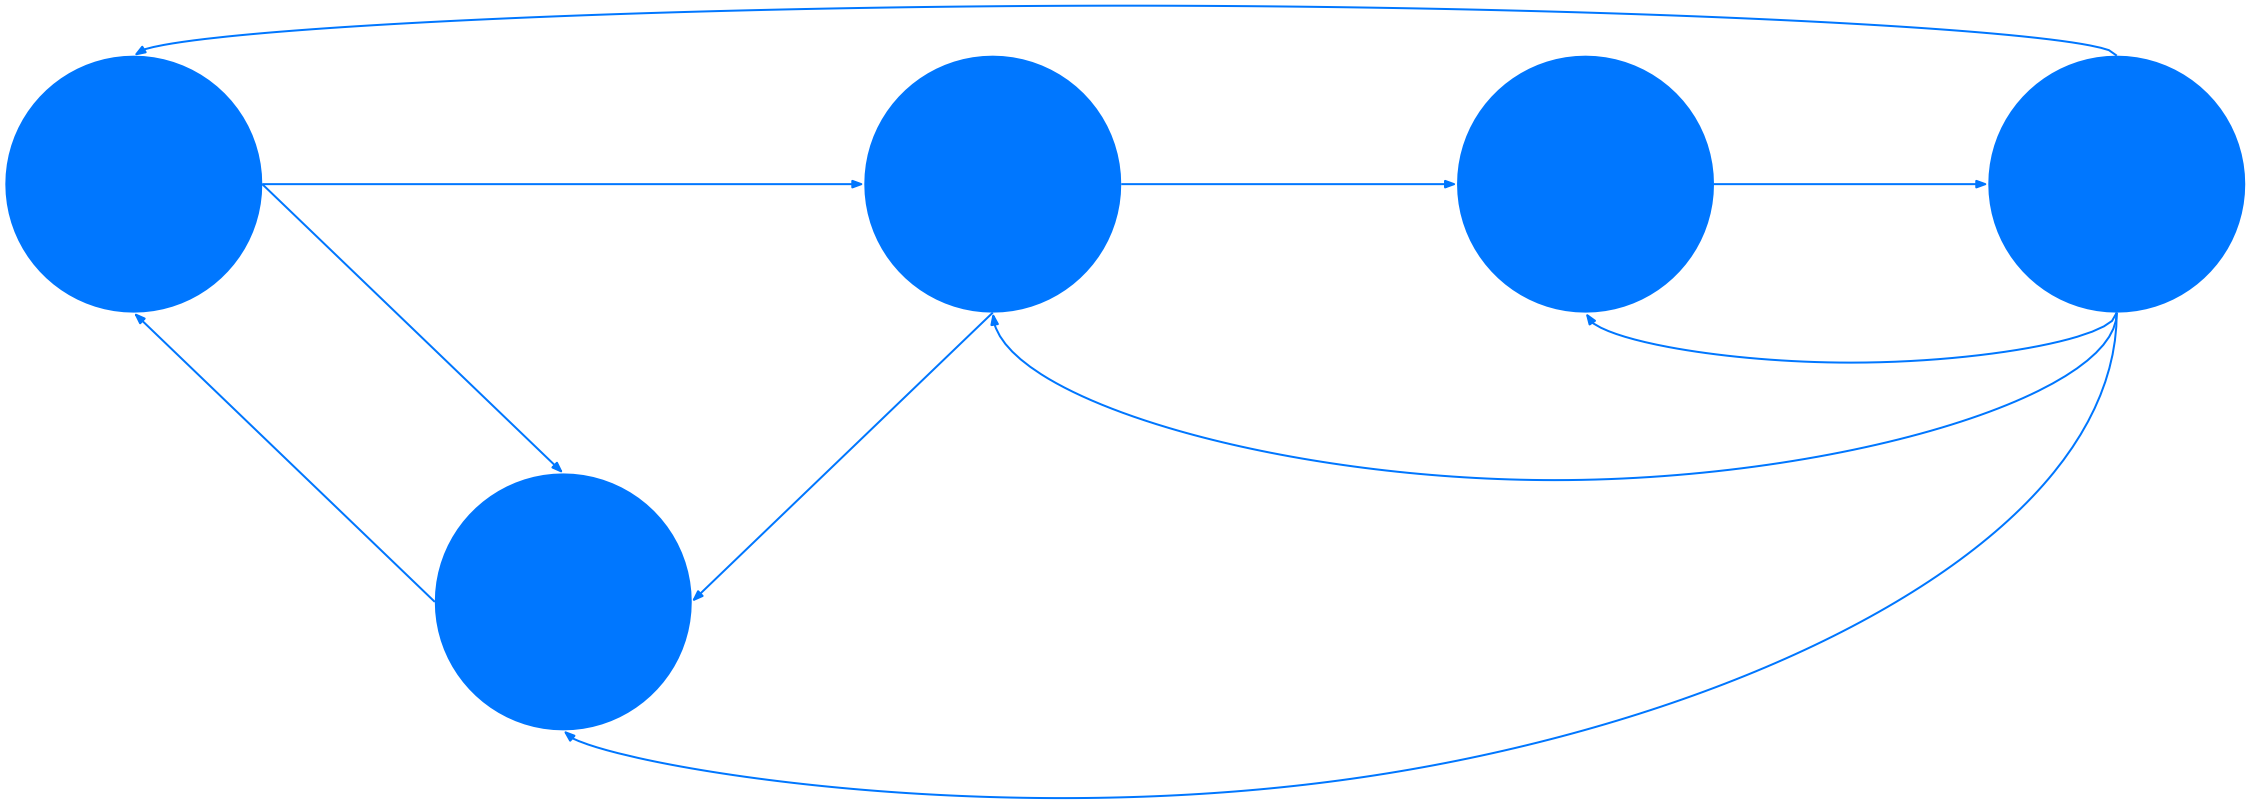
Висячие узлы: метод удаления

1. Итеративно удаляем висячие вершины
2. Вычисляем PageRank уже неразложимой цепи
3. Возвращаем удалённые вершины
4. Повторяем расчёт PageRank по количеству удалённых вершин



Висячие узлы: добавление связей

- Пользователь может перейти на любую страницу в интернете
- Вероятность такого перехода может быть неодинаковой



Телепортации

- Пользователь переходит по ссылкам с вероятностью d
- С вероятностью (1—d)v [j] переходит на страницу j (если попал в висячую вершину или просто решил перейти на другой сайт)

d ≈ 0,85-0,9

- Чем больше, тем точнее, но сходится медленнее
- Чем меньше, тем чувствительнее к спаму

Подведём итоги

1. Ссылочное ранжирование оценивает важность страницы **через структуру ссылок**: чем больше качественных сайтов ссылается на страницу, тем выше её **авторитет** в поисковой системе

2. Алгоритмы ссылочного анализа (например, **HITS**) разделяют сайты на «хабы» и «авторитеты» где хабы указывают на полезные ресурсы, а авторитеты содержат ценный контент

3. **PageRank** моделирует поведение пользователя как **случайные переходы** по ссылкам, распределяя «вес» страниц в зависимости от **вероятности** попадания на них

4. **PageRank** можно интерпретировать как стационарное распределение **цепи Маркова,** где каждая страница имеет устойчивую вероятность посещения

5. **Висячие узлы** (страницы без исходящих ссылок) **искажают расчёт ранжирования**, поэтому в алгоритмах применяются специальные методы их обработки

6. Механизм **телепортации** учитывает, что пользователь может перейти на любую страницу **случайно**, что делает модель более устойчивой и приближенной к реальному поведению

7. **Ссылочные** факторы лишь **часть** ранжирования, и в современных системах они дополняются **поведенческими** сигналами пользователей

Поведенческое ранжирование

Как отслеживать поведение пользователя

В качестве поведенческих сигналов могут быть: клики, просмотры, свайпы и тд

Откуда их взять?

Из логов фронтенда можно стащить

1) Логи запросов (что за запрос, кто задал)
2) Логи показов (какие url показали, какой серп)
3) Логи кликов (куда кликает, на какие документы)

На основе логов мы можем посчитать свою статистику и ранжировать по данной статистике



Примитивная модель ctr (click-through rate)

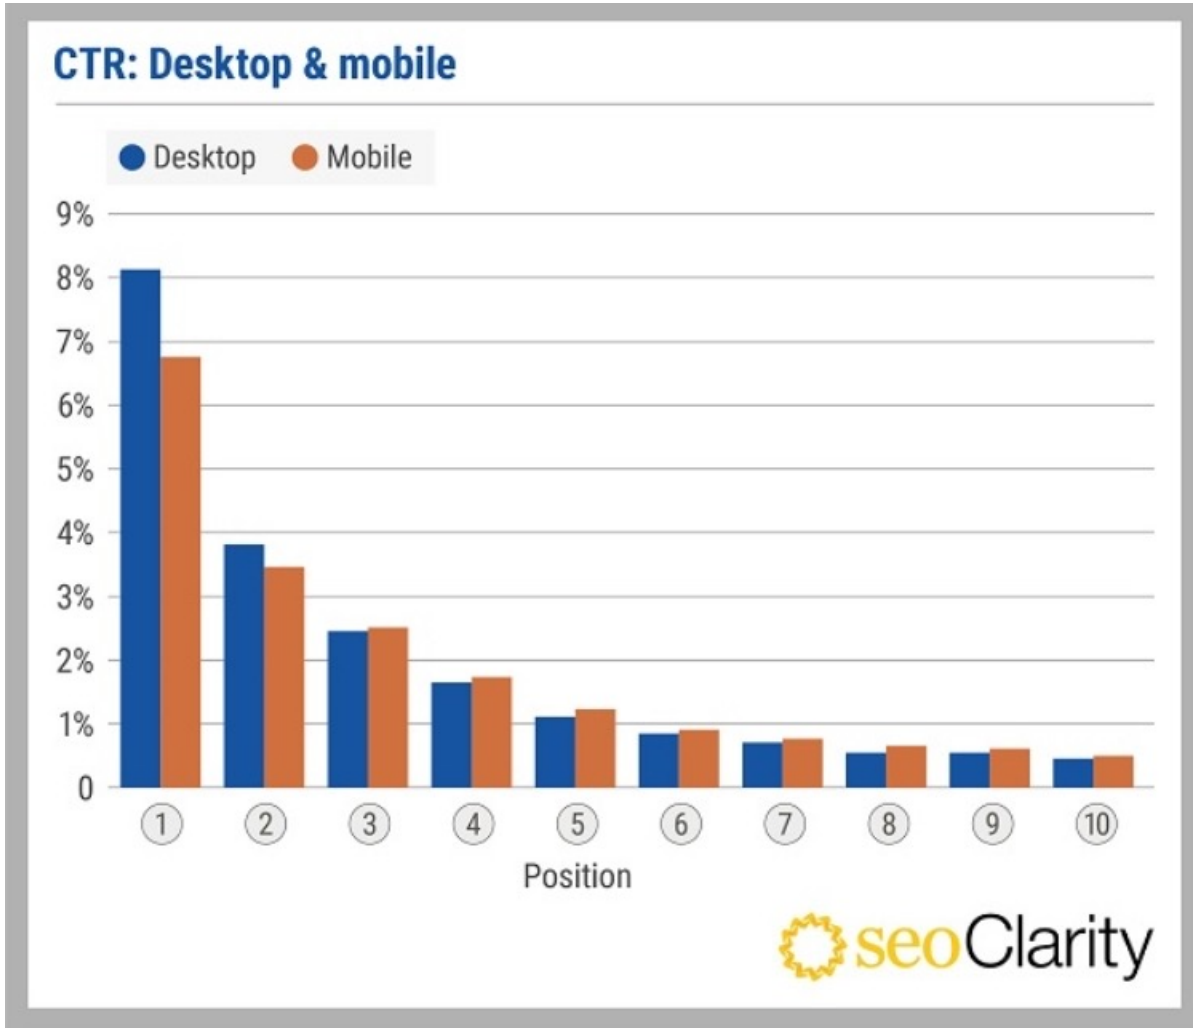
Давайте посчитаем для каждого документа следующую величину

$$\text{CTR} = \frac{click}{show}$$

Получим следующую статистику по документам

Q=нисан	показы	клики	ctr
Nissan.ru	4921	3167	0,64
Major-Nissan.ru	1498	486	0,32
Cars.mail.ru/nissan	4314	133	0,031

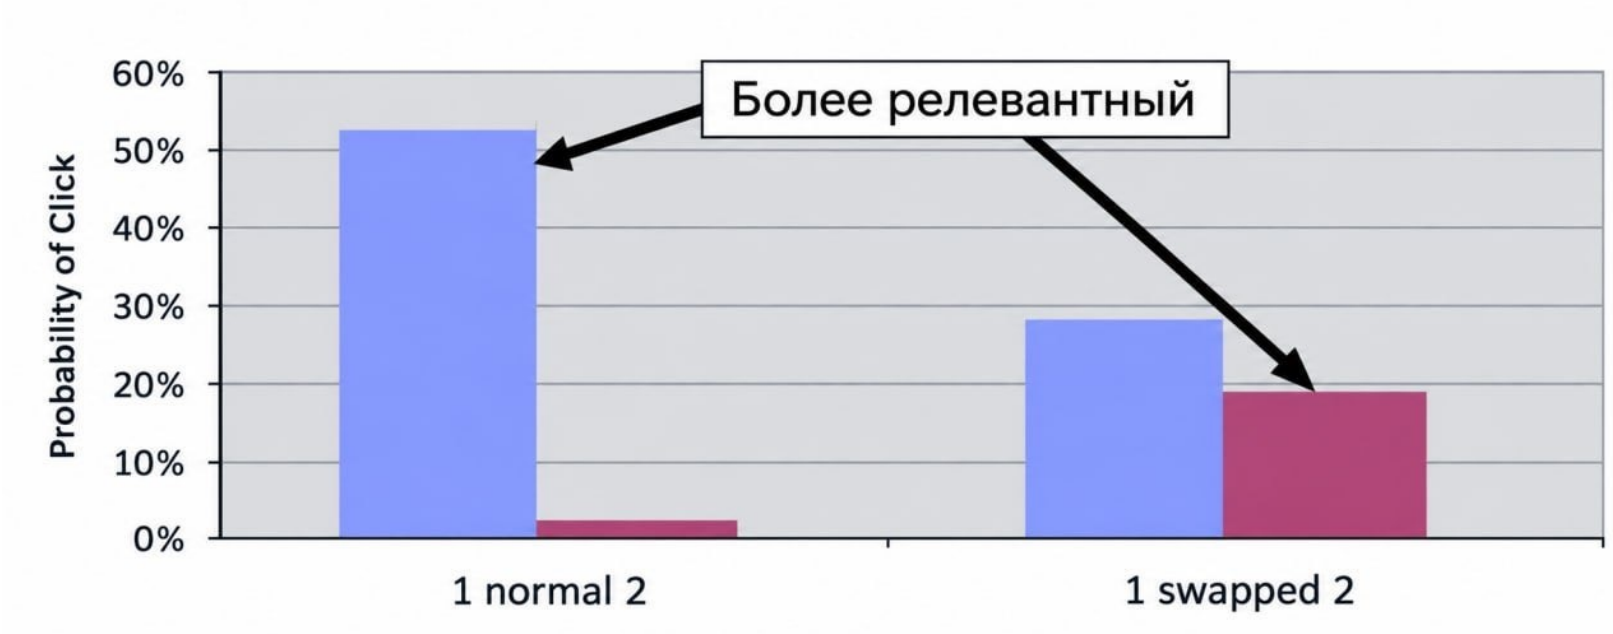
Распределение кликов



Означает ли это, что на первой позиции хороший документ, а
На второй позиции документ хуже ?

Positional bias

А что если мы сделаем такой эксперимент: поменять местами на первом и втором месте между собой релевантный и нерелевантный документ, как измениться ctr? Полностью ли он перетечет в релевантный документ



Оказывается что пользователи доверяют поиску и они все равно начинают кликать часто на первый элемент, не смотря на то, что он нерелевантен

Как будем учитывать positional bias

Positional-based models

E_r – с. в. Бинарная, которая отвечает на вопрос «Был ли прочитан документ на позиции r»

C_u – с. в. Бинарная, которая отвечает на вопрос «Был ли кликнут документ с адресом $= u$»

A_{qu} – с. в. Бинарная, которая отвечает на вопрос «Был ли привлекателен документ с адресом $= u$ по запросу q для пользователя»

Исходя из того как мы определили, считаем что $A_{qu} = 1$ и $E_r = 1$ независимые друг от друга

Клик выполняется только когда два условия соблюдены

Следовательно

$$P(C_u = 1) = P\left(A_{qu} = 1\right) * P(E_r = 1)$$

Для обучения используем – EM алгоритм. На последнем шаге ранжируем по аттрактивности

Каскадная модель

При каскадной гипотезе у нас выдвигаются следующие гипотезы поведения пользователя

1) Читаем документы сверху вниз
2) Один по одному документ смотрим
3) Если кликнули то дальше не смотрим

P($E_r = 1$ |E_{r-1} = 0) = 0
P($E_r = 1$ |C_{r-1} = 1) = 0
P($E_r = 1$ |E_{r-1} = 1, C_{r-1} = 0) = 1

Вероятность дойти до позиции r

$$\Pr(E_r = 1) = \prod_{k<r} \left(1 - \Pr\left(A_{qu_k} = 1\right)\right)$$

Вероятность клика по документу u на позиции r:

$$\Pr(C_u = 1) = \Pr\left(A_{qu_r} = 1\right) \prod_{k<r} \left(1 - \Pr\left(A_{qu_k} = 1\right)\right)$$

Ctr как фичи

CTR можно использовать не только для прямого ранжирования документов, но и как отдельную фичу в модели ранжирования.
Он отражает поведение пользователей и может дополнить текстовые, поведенческие и контекстные признаки.
Для редких запросов и документов CTR необходимо сглаживать, чтобы избежать нестабильных оценок при небольшом числе показов. Возможные варианты: байесовское сглаживание

Спасибо
за внимание!

education