education

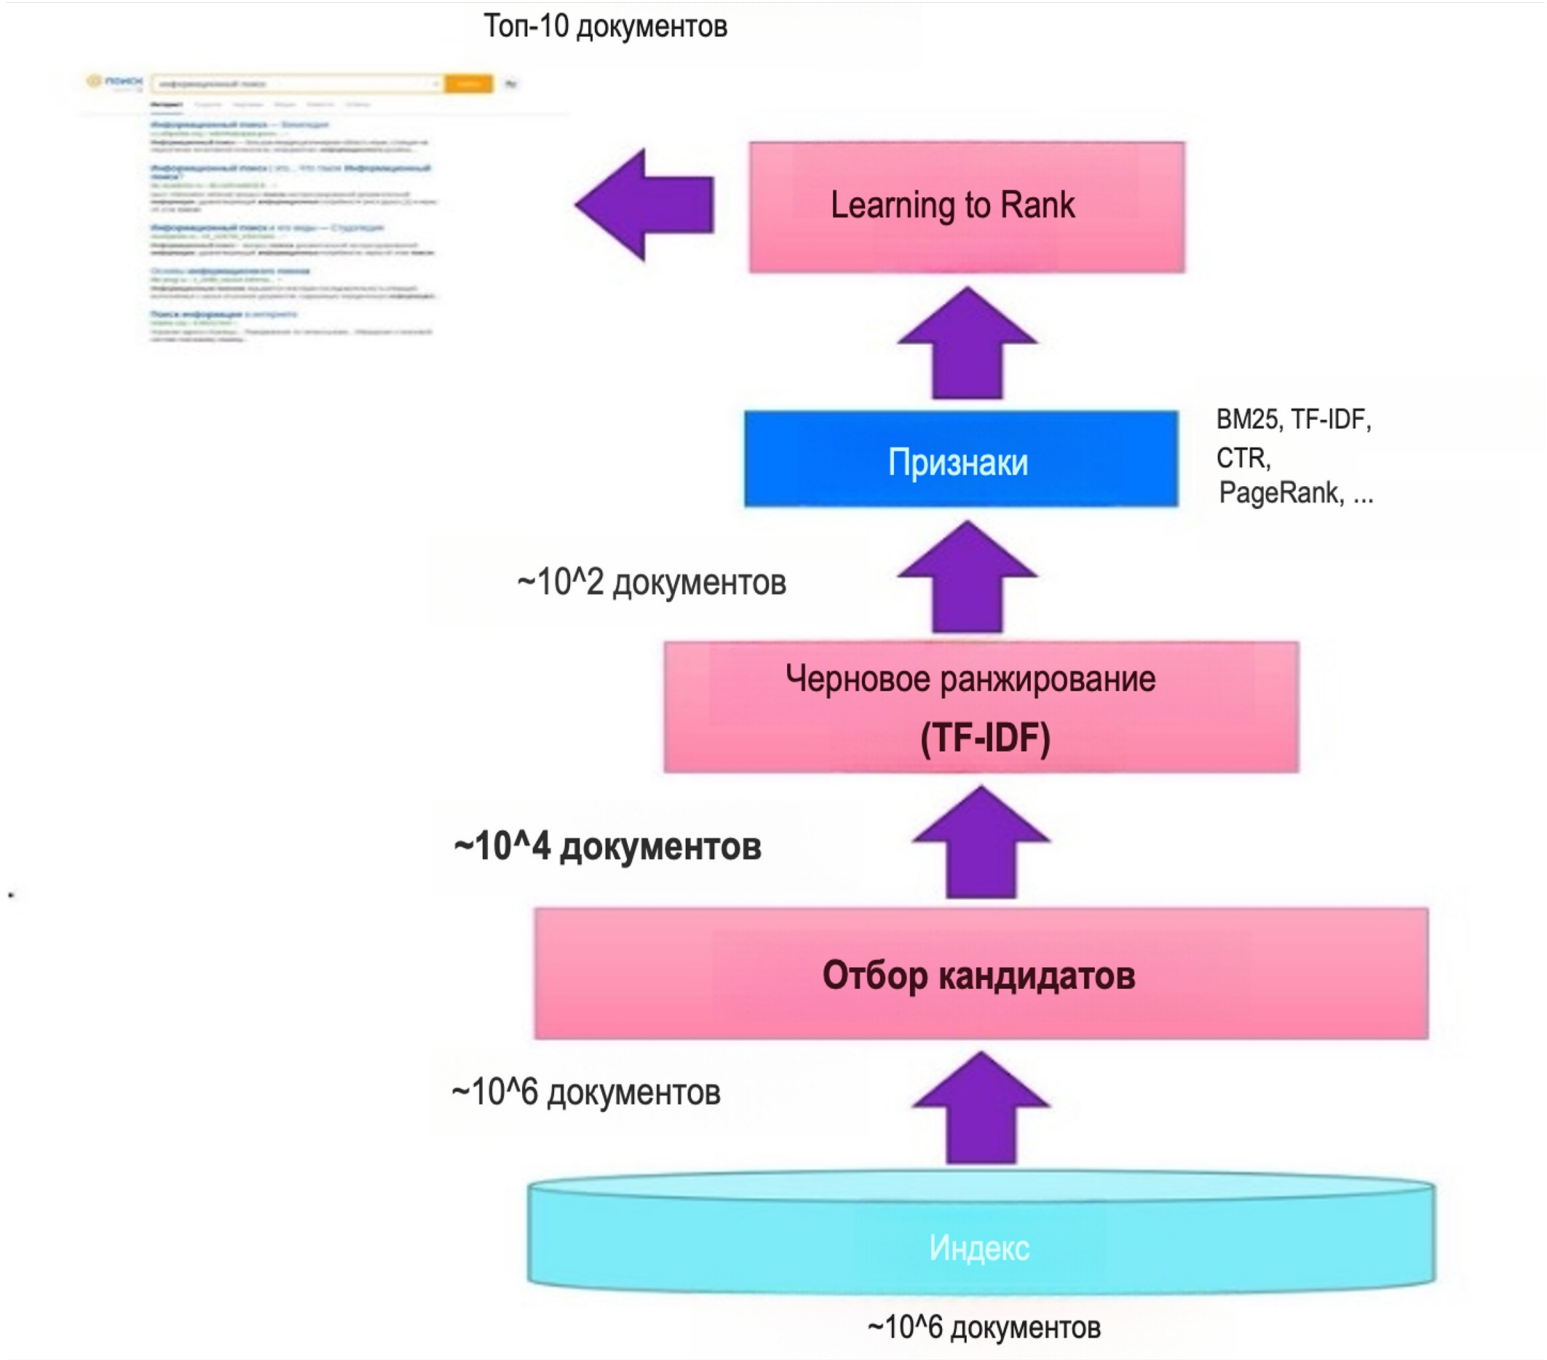
Постановка задачи ранжирования, метрики ранжирования

Информационный поиск и ранжирование

Цель занятия

Понять, как формулируется задача ранжирования и из каких компонентов строится модель ранжирования (объекты, признаки, таргет, метрики)

Мы сейчас тут 👀



Вспомним некоторые варианты постановки задачи машинного обучения с учителем

1

Классификация — учимся предсказывать класс (-ы) объекта

2

Регрессия — предсказываем некоторые действительные числа

3

Ранжирование — ?

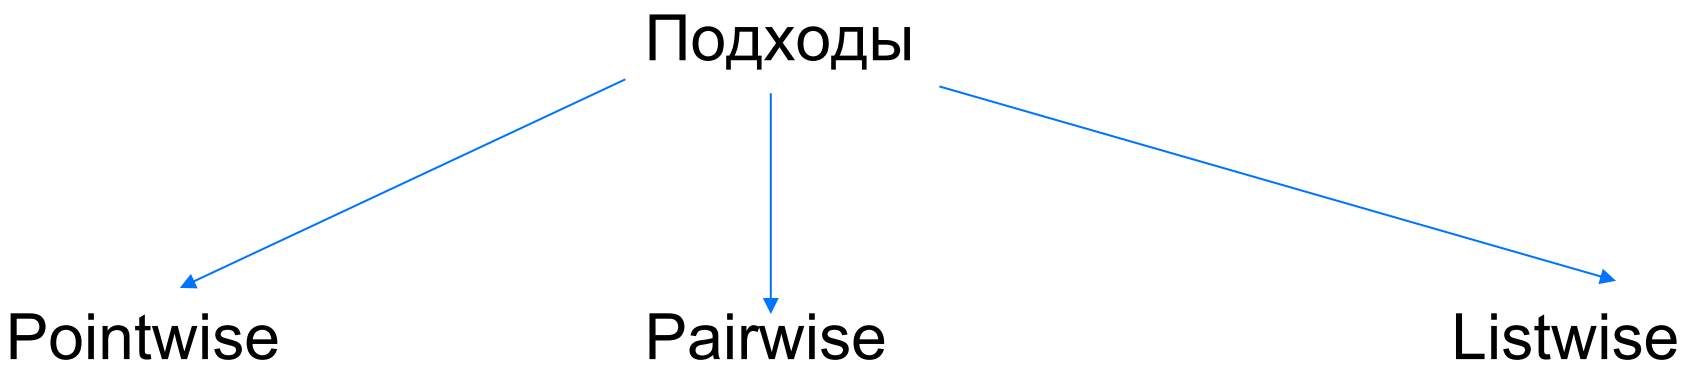
Постановка задачи ранжирования в общем случае

Дано:

- q- запрос
- d – документ
- y- релевантность

Задача

- Построить ранжирующую функцию $\alpha: X \rightarrow R$ такую, что: $i<j \Rightarrow \alpha(x_i)<\alpha(x_j)$



Откуда взять признаки?

Раз объект — это пара из документа и запроса, нужно подобрать признаки, которые будут отображать:

1. Соответствие документа запросу — хотим давать пользователю запрашиваемую информацию
2. Общую привлекательность документа — хотим давать качественную информацию

Тип признака	Примеры
Текстовые	• TF-IDF • BM25 • Длина документа • …
Поведенческие	• Число кликов/просмотров • ctr • …
Нейрофичи	• Косинус между эмбеддингами запроса и документа • …
…	…

Откуда взять таргет?

Разобрались с тем, что является объектами, – откуда будем брать релевантность?

Самый показательный способ получить релевантность – составить инструкцию по её оценке и использовать асессоров.

Но есть и множество других вариантов (действия пользователей)



суп пюре без картошки

Россия [188]

Позиция	Серп	Оценка
1	http://dzen.ru/a/ZMO8UArLp1wBHapW	3
2	http://dzen.ru/a/XHuN7HzyvwCy_F03	3
3	http://dzen.ru/a/XtTh0eD9Qk7U35md	3
4	http://dzen.ru/a/Y7Hx8w9kbUua6CB9	3
5	http://dzen.ru/a/ZDTbzy_Bu0hZ1WvN	1
6	http://dzen.ru/a/XJ-UzlMjmgCzpydd	3
7	http://dzen.ru/a/Ys752RXWelIvXHzv	1
8	http://dzen.ru/a/Wsm3AWEEk4W2X0DM	1
9	http://dzen.ru/a/XIOEaNI1AwC0fM_Q	1
10	http://dzen.ru/a/X9YVDjPtQgw_Rzwh	1

Pointwise

В данной постановке задачи наши данные представлены в виде множества троек

$$X = \{(q_i, d_i, y_i)\}_{i=1}^{N}$$

Пытаемся построить модель, которая бы предсказывала релевантность документа по данному запросу

$$a \quad (q_i, d_i) \approx y_i$$

Основная проблема подхода:



Pairwise

В данной постановке задачи наши данные представлены в виде множества троек

$$X = \left\{\left(q_i, d_i^{(1)}, d_i^{(2)}\right)\right\}_{i=1}^{N}$$

Модель должна обеспечить правильный порядок документов

$$a\left(q_i, d_i^{(1)}\right) < a\left(q_i, d_i^{(2)}\right)$$

Listwise

В данной постановке задачи наши данные представлены в виде множества троек

$$X = \{(q_i, \pi_i(d_{i1}, \dots, d_{in}))\}_{i=1}^{N}\}$$

где π_i— правильный порядок документов для запроса q_i

Модель получает запрос и должна вернуть правильную перестановку документов

$$a: Q \to \pi(\mathcal{D}^n)$$

Подходы к Обучению моделей

Pointwise

Будем пытаться решить задачу ранжирования, как задачу регресии

$$L(h) = \sum_{q} \sum_{i=1}^{n_q} \big(y(q, d_i) - h(q, d_i)\big)^2$$

Много проблем:

1) Никак не учитывается, что нужно предсказать порядок объектов, а не оценки
2) На популярных запросах ведет непредсказуемо

Pairwise

Мы сводим ранжирование к бинарной классификации пар документов: модель должна определить, какой документ релевантнее. Недифференцируемую ошибку классификации заменяем гладкой функцией потерь, мажорирующей исходную ошибку.

$$L(h) = \sum_{q} \sum_{(q,d_i) \prec (q,d_j)} \left[h(x_j) - h(x_i) < 0 \right] \leq \sum_{q} \sum_{(q,d_i) \prec (q,d_j)} L\left(h(x_j) - h(x_i) \right) \to \min$$

Мажорирующие функции

$L(m) = (1 - m)_+$ - RankSVM

$L(m) = \log(1 + e^{-m})$ - RankNet

$L(m) = e^{-m}$ - RankBoost

RankNet

Модель следующая: $h(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle$

Лосс: $L(\mathrm{M}) = \log\bigl(1 + \exp(\sigma \mathrm{M})\bigr)$

Шагаем SGD по следующей формуле

$$\mathbf{w}_{t+1} = \mathbf{w}_t + \eta \frac{\sigma}{1 + \exp\bigl(\sigma\bigl[h_t(\mathbf{x}_i) - h_t\bigl(\mathbf{x}_j\bigr)\bigr]\bigr)} \bigl(\mathbf{x}_i - \mathbf{x}_j\bigr)$$

А будем ли мы при этом шаге оптимизировать NDCG?

Как оценить результат?

Предположим, мы построили алгоритм, как-то ранжирующий документы для запроса.

Как понять, хорошо ли мы построили алгоритм или какую из версий нам выбрать?

Вариант 1: посмотреть на поведенческие метрики (клики пользователей, просмотры и т. д.) — непозволительная роскошь при обучении модели машинного обучения.

Хотим иметь возможность быстро оценить качество, имея только датасет

Как оценить результат?

Предположим, мы построили алгоритм, как-то ранжирующий документы для запроса.

Как понять, хорошо ли мы построили алгоритм или какую из версий нам выбрать?

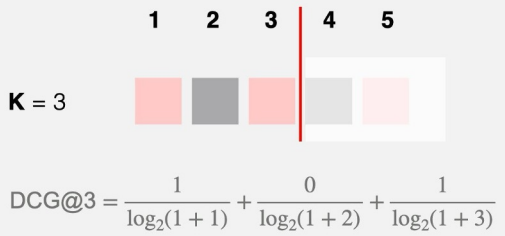
Вариант 2: офлайн-метрики качества поиска!

Вспомним некоторые из них

Рекап метрик

Вспомним, какие метрики мы используем для оценки качества поиска:

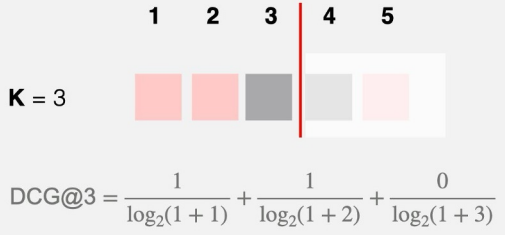
$$\text{DCG@K} = \sum_{k=1}^{K} \frac{rel_i}{\log_2(i+1)}$$



$$\text{DCG@3} = \frac{1}{\log_2(1+1)} + \frac{0}{\log_2(1+2)} + \frac{1}{\log_2(1+3)}$$

$$\text{DCG@3} = 1 + 0 + 0.5 = 1.5$$

$$\text{NDCG@K} = \frac{DCG@K}{IDCG@K}$$



$$\text{DCG@3} = \frac{1}{\log_2(1+1)} + \frac{1}{\log_2(1+2)} + \frac{0}{\log_2(1+3)}$$

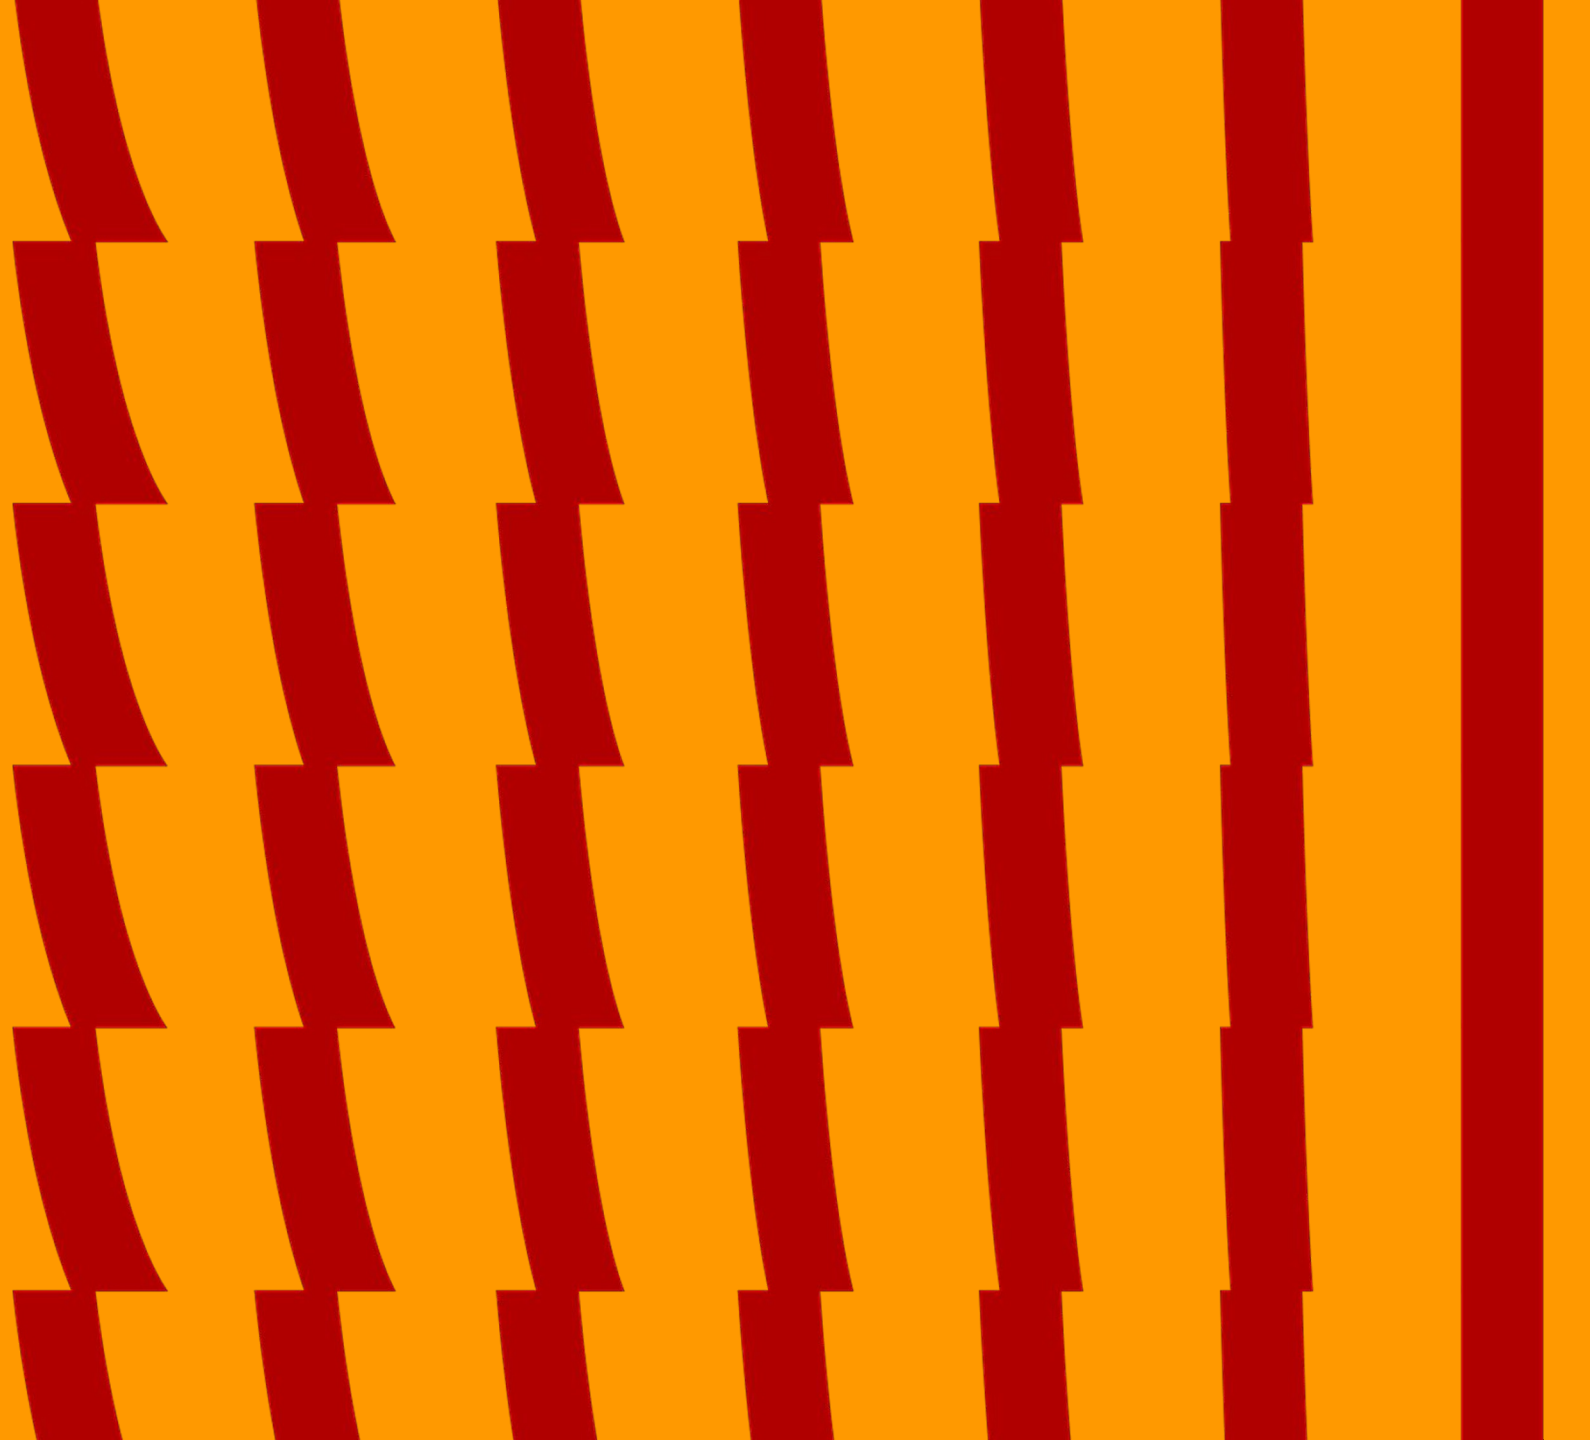
$$\text{DCG@3} = 1 + \frac{1}{1.585} + 0 \approx 1.63$$

LambdaNet

$\Delta\mathrm{NDCG}_{ij}$ — это абсолютное изменение метрики NDCG, при обмене позиций документов d_i, $\mathrm{d_j}$

$$\mathbf{w}_{t+1} = \mathbf{w}_t + \eta \frac{\sigma}{1 + \exp\left(\sigma\left[h_t(\mathbf{x}_i) - h_t(\mathbf{x}_j)\right]\right)} \left|\Delta\mathrm{NDCG}_{ij}\right|\left(\mathbf{x}_i - \mathbf{x}_j\right)$$

YetiRank



YetiRank

- Учёт неопределённостей оценок с помощью матрицы ошибок при подсчёте веса пары документов wij, с отражением вероятностной уверенности в том, что документ i действительно лучше документа j с учётом возможных ошибок асессоров

	Bad	Poor	Good	Exc.	Perf.
Bad	0.869	0.103	0.02	0.001	0.007
Poor	0.016	0.878	0.1	0.005	0.002
Good	0.003	0.098	0.85	0.046	0.004
Exc.	0	0.01	0.094	0.896	0
Perf.	0	0	0.019	0.016	0.965

$$w_{ij} = N_{ij} c(l_i, l_j),$$

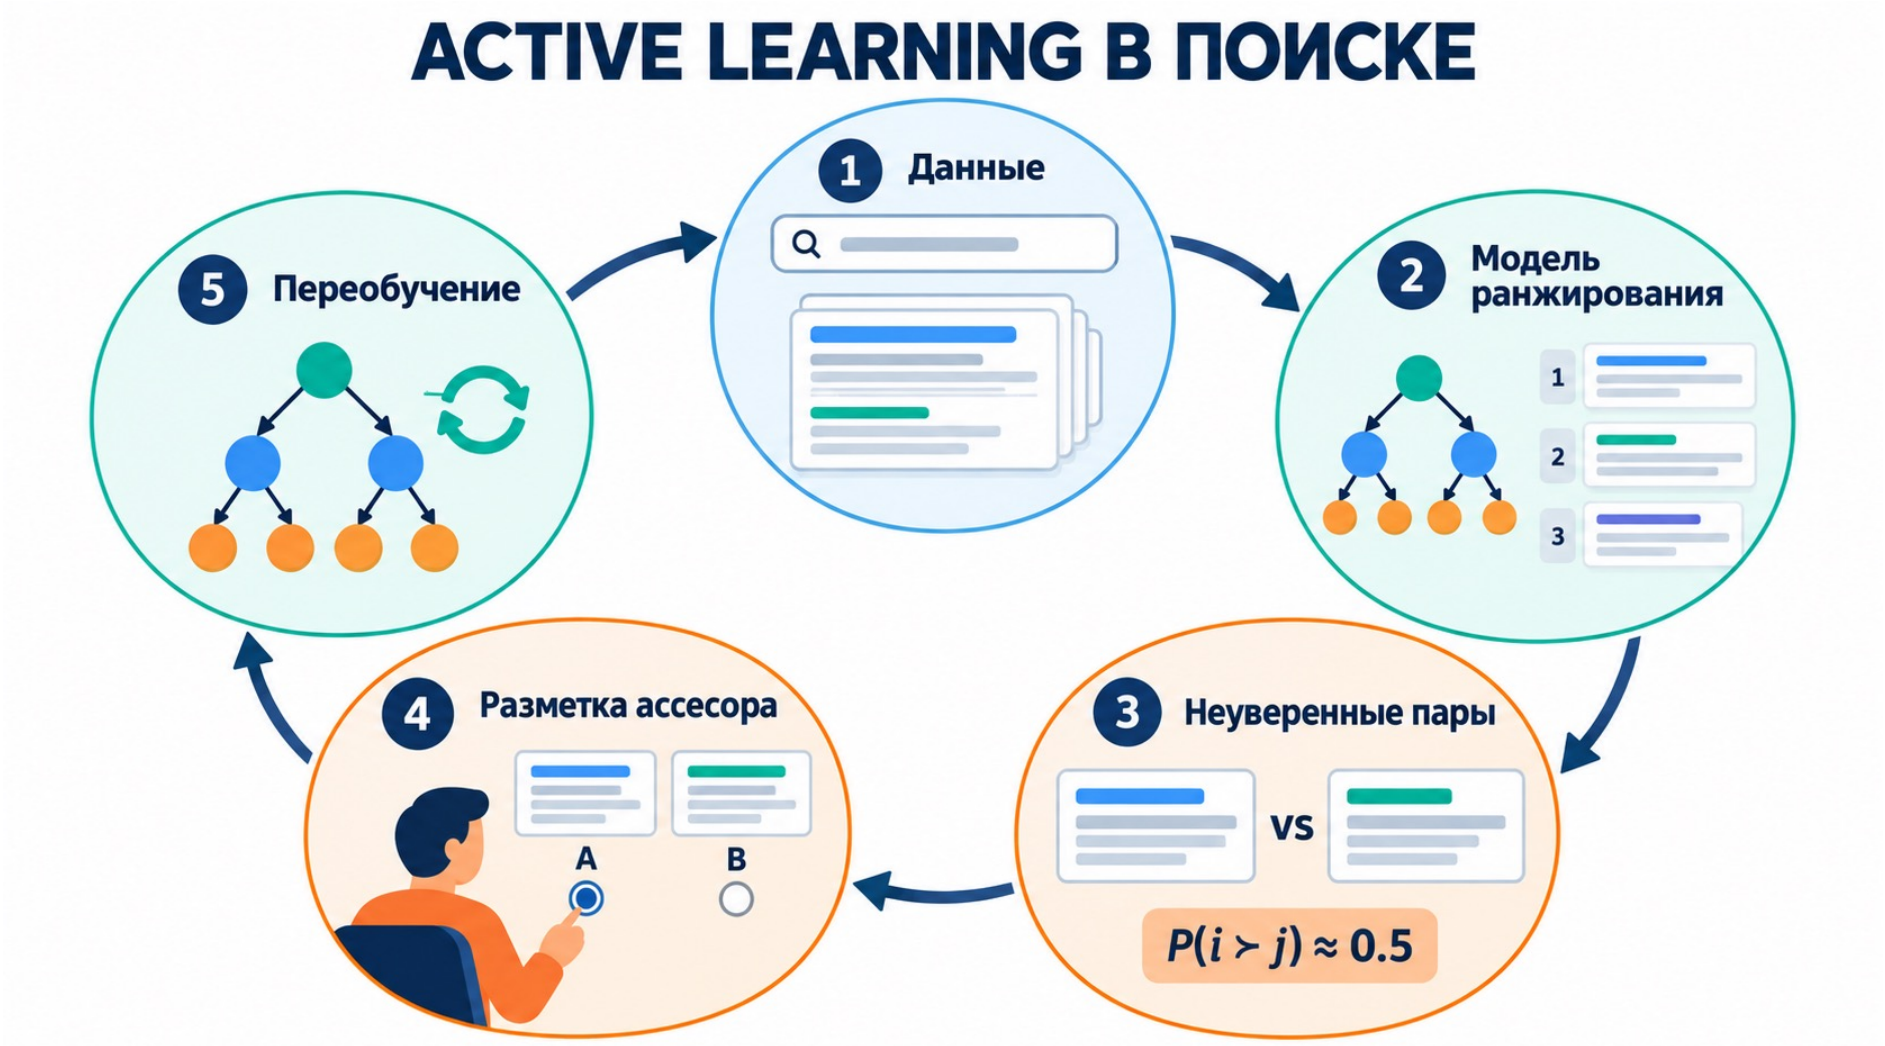
$$c(l_i, l_j) = \sum_u \sum_v 1_{u>v} p(u|l_i) p(v|l_j)$$

YetiRank

- Особый расчёт градиента (better gradient alignment)
- Стандартные методы градиентного бустинга для ранжирования (как LambdaRank) часто упрощают задачу

- YetiRank стремится напрямую минимизировать парную функцию потерь на каждой итерации построения дерева

$$\mathbb{L} = \sum_{ij} w_{ij} \left(c_{leaf(d_i)} - c_{leaf(d_j)} + \frac{e^{x_j}}{e^{x_i} + e^{x_j}} \right)^2$$


ACTIVE LEARNING В ПОИСКЕ
1 Данные
2 Модель ранжирования
1
2
3
3 Неуверенные пары
VS
$P(i \succ j) \approx 0.5$
4 Разметка ассесора
A
B
5 Переобучение

Спасибо
за внимание!

education